

RÔMULO PONCIANO DA SILVA FREITAS

DROPICT: UMA FERRAMENTA PARA MEDIAR A INTERAÇÃO DE
EDUCADORES COM MODELOS PREDITIVOS DE ALUNOS EM RISCO DE EVASÃO
NA EDUCAÇÃO À DISTÂNCIA

Dissertação de Mestrado apresentada ao
Programa de Pós-Graduação em Computação
da Universidade Federal Fluminense como
requisito parcial para a obtenção do Grau de
Mestre em Computação. Área de concentração:
Computação Visual.

Orientadora: Prof^a. Dr^a. Luciana Cardoso de Castro Salgado

Niterói
2020

Ficha catalográfica automática - SDC/BEE
Gerada com informações fornecidas pelo autor

F862d Freitas, Rômulo Ponciano da Silva
DROPICT: UMA FERRAMENTA PARA MEDIAR A INTERAÇÃO DE
EDUCADORES COM MODELOS PREDITIVOS DE ALUNOS EM RISCO DE EVASÃO
NA EDUCAÇÃO À DISTÂNCIA / Rômulo Ponciano da Silva Freitas ;
Luciana Cardoso de Castro Salgado, orientador. Niterói, 2020.
100 f. : il.

Dissertação (mestrado)-Universidade Federal Fluminense,
Niterói, 2020.

DOI: <http://dx.doi.org/10.22409/PGC.2020.m.13457111740>

1. Inteligência artificial. 2. Interação homem-máquina.
3. Ensino à distância. 4. Produção intelectual. I. Salgado,
Luciana Cardoso de Castro, orientador. II. Universidade
Federal Fluminense. Instituto de Computação. III. Título.

CDD -

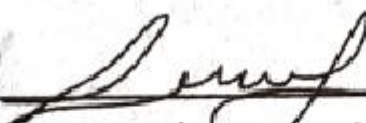
RÔMULO PONCIANO DA SILVA FREITAS

DROPICT: UMA FERRAMENTA PARA MEDIAR A INTERAÇÃO DE EDUCADORES
COM MODELOS PREDITIVOS DE ALUNOS EM RISCO DE EVASÃO NA EDUCAÇÃO
À DISTÂNCIA

Dissertação de Mestrado apresentada ao
Programa de Pós-Graduação em Computação
da Universidade Federal Fluminense como
requisito parcial para a obtenção do Grau de
Mestre em Computação. Área de concentração:
Computação Visual.

Aprovada em Abril de 2020.

BANCA EXAMINADORA



Prof. Luciana Cardoso de Castro Salgado, UFF – Presidente

Prof. Flavia Cristina Bernardini, UFF

Prof. Isabela Gasparini, UDESC

Niterói
2020

Dedico este trabalho a todos os educadores do Ensino à Distância.

AGRADECIMENTOS

Agradeço primeiramente à Deus. Sem Ele nada é possível. Agradeço a minha família, namorada e a todos que sempre estiveram ao meu lado. Agradeço aos educadores que aceitaram participar das etapas dessa pesquisa, à minha orientadora que tanto me ajudou nestes anos. Sem ela não teria conseguido chegar ao final. Agraço à Universidade pela oportunidade do Mestrado e a toda a banca que pontou detalhes essenciais sobre a pesquisa.

RESUMO

A Educação a Distância ainda sofre com uma alta taxa de evasão. Para enfrentar esse desafio, pesquisadores propuseram soluções que utilizam modelos preditivos para identificar alunos em risco de evasão. No entanto, alguns estudos mostram potenciais problemas na eficácia das decisões geradas por esses modelos preditivos. Além disso, novas leis, como a GDPR, determinam que esses modelos sirvam para apoiar as decisões finais. Neste trabalho, investigamos como a simulação de cenário pode ajudar os Educadores a identificar e questionar os resultados obtidos por meio desses modelos preditivos ao explorar lacunas na predição de alunos em risco de abandono. Para isso, realizamos um Mapeamento Sistemático da Literatura e um conjunto de entrevistas para identificar as características mais impactantes para a predição de evasão dos alunos. Esses estudos nos permitiram visualizar os atributos escolhidos pela literatura ao desenvolver os modelos preditivos, e as entrevistas forneceram informações com a experiência dos educadores sobre o assunto. A partir destes resultados implementamos a Dropict, uma ferramenta que permite que os educadores realizem simulações com os modelos preditivos, para que seja possível comparar e avaliar seus resultados. Por fim, realizamos avaliações com educadores da EAD que descreveram sua opinião sobre essa experiência. Concluimos demonstrando as limitações e pontos positivos da ferramenta Dropict.

Palavras-chave: Educação à distância; Inteligência Artificial; Explicação em IA; Simulação; IHC

ABSTRACT

Distance Education still suffers from a high dropout rate. To address this challenge, researchers have proposed solutions that use predictive models to identify students at risk of dropout. However, some studies show potential problems in the effectiveness of decisions generated by these predictive models. Also, new laws such as GDPR, dictate that these models should serve to support final decisions. In this work, we investigate how scenario simulation can assist Educators in identifying and questioning the results obtained through these predictive models when exploring gaps in the prediction of students at risk of dropout. For this, we conducted a Systematic Mapping of Literature and a set of interviews to identify the most impacting characteristics for students' prediction of dropout. These studies allowed us to visualize the attributes chosen by the literature when developing the predictive models, and the interviews provided information with the educators' experience on this subject. We implemented Dropict, a tool that allows Educators to carry out simulations with the predictive models so that it is possible to compare and evaluate their results. Finally, we conducted evaluations with Distance Education Educators who described their opinion on this experience. We conclude by demonstrating the limitations and positive points of the Dropict tool.

Keywords: Distance Education; Artificial Intelligence; Explainable AI; Simulation; HCI

LISTA DE ILUSTRAÇÕES

Figura 1: Proposta de pesquisa.	17
Figura 2: Processo para treinamento e uso de um modelo preditivo supervisionado...	23
Figura 3: Interface do EWS desenvolvido por Wolff e colegas	29
Figura 4: Interface do EWS para os alunos, desenvolvida por Hu e colegas	30
Figura 5: Interface do EWS para os educadores, desenvolvida por Hu e colegas.....	31
Figura 6: Interface da ferramenta proposta por Chen e colegas	32
Figura 7: Interface de Kotsiantis e Pintelas para uso do modelo preditivo treinado	33
Figura 8: Distribuição top 10 atributos ao longo dos anos (2002-2018)	45
Figura 9: Percentual de trabalhos em cada categoria de finalidade	46
Figura 10: Atributos distribuídos por finalidade	47
Figura 11: Porcentagem por modelo de EAD.....	48
Figura 12: Atributos por modelo de EAD	49
Figura 13: Quantidade de autores por país	49
Figura 14: Funcionamento da ferramenta.....	59
Figura 15: Estrutura da ferramenta Dropict.....	60
Figura 16: Distribuição do atributo Idade.....	64
Figura 17: Distribuição do atributo Renda_Familiar.....	64
Figura 18: Fórmula para normalização Min Max	65
Figura 19: Resultados de testes para encontrar o melhor k	67
Figura 20: Árvore de Decisão final para o modelo preconceituoso	69
Figura 21: Tela para seleção do modelo preditivo.....	73
Figura 22: Tela para seleção de alunos.....	74
Figura 23: Interface onde o usuário consegue realizar e visualizar suas simulações ...	75
Figura 24: Comparação entre dados originais e cenários simulados	75

LISTA DE TABELAS

Tabela 1: Resultado inicial em cada MBA	43
Tabela 2: Resultado filtrado em cada MBA	44
Tabela 3: Quantidade de trabalhos em relação aos atributos utilizados	44
Tabela 4: Comparação entre métodos de otimização de pesos e camadas x neurônios	70

LISTA DE ABREVIATURAS E SIGLAS

Educação à Distância (EAD)
Instituições de Ensino (IE)
Tecnologias de Comunicação e Informação (TICs)
Ambientes Virtuais de Aprendizagem (AVA)
Massive Open Online Course (MOOC)
General Data Protection Regulation (GDPR)
Lei de Proteção de Dados Brasileira número 13.709 (LPD-Br)
Mapeamento Sistemático da Literatura (MSL)
Inteligência Artificial (IA)
World Wide Web (WWW)
Ensino Híbrido (EH)
Explainable Artificial Intelligence (XAI)
Engenharia Semiótica (ES)
Early Warning System (EWS)
k Nearest Neighbors (k-NN)
Critérios de inclusão (CI)
Critérios de exclusão (CE)
Centro de Educação à Distância do Estado do Rio de Janeiro (CEDERJ)
Centro Federal de Educação Tecnológica Celso Suckow da Fonseca (CEFET-RJ)
Universidade Federal do Rio de Janeiro (UFRJ)
Universidade do Estado do Rio de Janeiro (UERJ)
Universidade Estadual do Norte Fluminense Darcy Ribeiro (UENF)
Universidade Federal Fluminense (UFF)
Universidade Federal do Estado do Rio de Janeiro (UNIRIO)
Universidade Federal Rural do Rio de Janeiro (UFRRJ)
Application Programming Interface (API)
Representational State Transfer (REST)
JavaScript Object Notation (JSON)
Cascading Style Sheets (CSS)
Instituto Federal do Mato Grosso (IFMT)
Multilayer Perceptron (MLP)
Limited-memory Broyden–Fletcher–Goldfarb–Shanno (LBFGS)
Stochastic Gradient Descent (SGD)
Adaptive Moment Estimation (Adam)

SUMÁRIO

Capítulo 1 – Introdução	15
1.1 Motivação e definição do problema	16
1.2 Proposta de pesquisa	17
1.3 Organização	18
Capítulo 2 – Conceituação	20
2.1 Educação à distância	20
2.2 Evasão na educação à distância	21
2.3 Inteligência artificial	21
2.4 Explicação em inteligência artificial	23
2.4.1 Modelos preditivos explicáveis	24
2.4.2 Direito à explicação em IA	24
2.5 Engenharia semiótica	25
Capítulo 3 – Trabalhos relacionados	27
Capítulo 4 – Estudo realizado	36
4.1 Paradigma	36
4.2 Metodologia	37
4.3 Mapeamento sistemático da literatura	39
4.3.1 String de busca	39
4.3.2 Mecanismos de busca acadêmica	40
4.3.3 Critérios de inclusão e exclusão	41
4.3.4 Extração dos dados do msl	42
4.3.5 Filtragem dos estudos	43
4.3.6 Atributos extraídos	44
4.3.7 Comportamento dos atributos ao longo do tempo	45
4.3.8 Comportamento dos atributos em relação à finalidade dos trabalhos	46
4.3.9 Contexto dos dados	47

4.3.10 Limitações do MSL	49
4.4 Entrevistas para identificar características relacionadas ao abandono na EAD ..	50
4.4.1 Definição do objetivo e perfil desejado para as entrevistas.....	51
4.4.2 Tipo de entrevista escolhida	52
4.4.3 Perguntas para as entrevistas	53
4.4.4 Condução das entrevistas.....	54
4.4.5 Análise das entrevistas.....	55
4.4.6 Resultado das entrevistas	55
4.5 MSL x Entrevistas	58
Capítulo 5 – Dropict	59
5.1 Funcionamento da ferramenta	59
5.2 Estrutura da ferramenta.....	59
5.3 Desenvolvimento	61
5.3.1 Aplicação web	61
5.3.2 API.....	61
5.3.3 Modelos preditivos	62
5.4 Design da interface para a dropict	71
5.4.1 Definições para o espaço de design	71
5.4.2 Metacomunicação da ferramenta dropict.....	72
5.4.3 Processo interativo básico.....	73
Capítulo 6 – Avaliação das simulações	77
6.1 Requisitos para os participantes.....	77
6.2 Procedimentos.....	77
6.3 Análises.....	79
6.4 Resultados.....	80
6.4.1 Perfil dos educadores	80
6.4.2 Modelo preditivo: árvore de decisão	81

6.4.3 Módulo preditivo: rede neural	82
6.5 Limitações da análise.....	83
Capítulo 7 – Conclusões	84
7.1 Até que ponto os usuários conseguiram identificar preconceitos no uso da Árvore de Decisão?.....	84
7.2 Até que ponto a simulação de cenários permite o questionamento dos resultados em modelos preditivos no contexto de evasão no EAD?	84
7.3 Discussão final.....	84
7.4 Limitações da pesquisa	85
7.5 Trabalhos futuros	86

CAPÍTULO 1 – INTRODUÇÃO

A Educação à Distância (EAD) surgiu para suprir a necessidade de ensinar aqueles que não podiam se deslocar às Instituições de Ensino (IE). Até metade do final do século XX, a EAD era realizada e discutida sob a perspectiva de comunicação postal individual entre professor e aluno. Porém, foi a partir dessa época que o modo como o EAD é aplicado mudou e evoluiu rapidamente, à medida que novos meios de comunicação emergiram (Anderson 2008; Harasim 2000).

Tais evoluções nas Tecnologias de Comunicação e Informação (TICs) definiram, segundo Anderson (2008), cinco gerações desta modalidade de ensino: i) EAD baseado nas trocas por correspondência postal; ii) EAD com suporte de televisores e rádios; iii) EAD com suporte de vídeo e áudio conferências; iv) EAD apoiada pelos computadores; e, v) EAD com apoio de agentes autônomos e inteligentes (Anderson 2008; Anderson and Whitelock 2004).

Apesar do uso da tecnologia na EAD ser discutido desde a segunda geração (Harasim 2000; Mayer 2009; Moore, Dickson-Deane, and Galyen 2011), nas últimas décadas as novas gerações de EAD ganharam mais espaço, em todo o mundo, graças a diversos fatores, tais como: a disseminação e maior acesso à Internet, computadores pessoais e tecnologias da informação; o menor custo econômico neste tipo de ensino em relação ao ensino presencial; e o crescente número de estudantes que precisam estudar em dias e horários que não refletem os horários disponibilizados pelas universidades (Cai and Guo 2006; Means et al. 2009; Sesabo, Mfaume, and Msabila 2015; Snyder, Dillow, and Hoffman 2009). Outro fator muito importante para uma adesão maior ao EAD foi o desenvolvimento e aprimoramento de plataformas, chamadas Ambientes Virtuais de Aprendizagem (AVA), onde os alunos podem acessar o conteúdo de seus cursos (Ribeiro, Aquino, and Furtado 2007).

Nas últimas décadas, o EAD foi usado por 74% das pessoas que realizaram alguma formação acadêmica no continente Africano (Isaacs 2014; Sesabo, Mfaume, and Msabila 2015), 67.9% das universidades da China (Cai and Guo 2006), 65% dos cursos oferecidos pela Open University UK, no Reino Unido (Baxter 2012; Hanson 2009) e em mais de 36% das instituições nos Estados Unidos (Means et al. 2009; Snyder, Dillow, and Hoffman 2009). No Brasil, em 2018, quase 40% de todos os alunos ingressantes no Ensino Superior eram alunos na modalidade de EAD (INEP 2018).

1.1 MOTIVAÇÃO E DEFINIÇÃO DO PROBLEMA

Apesar do grande crescimento em diversas partes do mundo, o EAD ainda sofre um grande problema: o alto número de abandono (Cai and Guo 2006; Means et al. 2009; Sesabo, Mfaume, and Msabila 2015; Snyder, Dillow, and Hoffman 2009). No Brasil, os dados estatísticos do Ensino Superior demonstram que apenas 21.7% de todos os alunos inscritos em cursos com EAD terminam os cursos em 2018 (INEP 2018). Jordan (2014) apresentou um trabalho que demonstrava um índice de conclusão nos cursos à distância totalmente abertos (MOOCs) menor que 10%, em escala global. Porém, esse problema do abandono é estudado desde 1999, com Phipps e Merisotis (1999), e ainda é estudado na década atual com trabalhos mais recentes, de 2012 e 2015 (Baxter 2012; Diver and Martinez 2015).

Atualmente, uma abordagem apontada para encaminhar a solução para esse problema é a utilização de modelos desenvolvidos para a predição de alunos com potencial para o abandono na EAD. Espera-se, através dessa identificação, evitar que o aluno realmente abandone o curso (Liang, Li, and Zheng 2016; Niemi and Gitin 2012). Essa proposta surgiu devido à grande coleta de dados em diversas esferas em conjunto com um maior poder computacional (Vitiello et al. 2017).

Entretanto, como Joh (2016) demonstra, os dados usados para o treinamento e geração dos modelos podem conter viés cultural e, assim, levar o modelo a tomar decisões baseadas em preconceitos ou contextos que não refletem a realidade vivida onde o modelo é aplicado. Além disso, sabe-se que os modelos preditivos não acertam 100% dos casos. Então, mesmo os melhores modelos ainda podem errar. Ao juntar os estes dois problemas, podemos ter predições erradas que atrapalhem o resgate de alunos em risco de evasão. Esse tipo de questionamento também foi um reforço para a criação de leis como a General Data Protection Regulation (GDPR)¹ e a Lei de Proteção de Dados Brasileira número 13.709 (LPD-Br)².

Estas leis levantam a necessidade de explicações sobre as predições para que os usuários finais saibam os motivos por trás das predições. Além disso, as leis também levantam a questão da inserção de humanos no processo de decisão dos modelos preditivos. Sendo assim, neste momento, temos uma necessidade para a inserção de educadores neste processo das decisões geradas pelos modelos preditivos e outra necessidade para que os educadores consigam investigar estes modelos. Portanto, diante dos aspectos citados, consideramos oportuno

¹ <https://eugdpr.org/>

² http://www.planalto.gov.br/ccivil_03/_Ato2015-2018/2018/Lei/L13709.htm

pesquisar uma forma para que os educadores investiguem e questionem os resultados gerados pelos modelos preditivos.

1.2 PROPOSTA DE PESQUISA

Como os modelos preditivos classificatórios geram seus resultados à partir de dados de entrada (veja Capítulo 2 para maiores detalhes), propomos que o educador simule resultados baseados em suas próprias escolhas, à partir de uma predição já realizada. Na Figura 1 podemos observar, através das setas em azul, o processo de predição que ocorre atualmente: dados do aluno são enviados para um modelo preditivo que realiza a predição positiva ou negativa para evasão. Com nossa proposta, o processo será alterado com a adição dos passos A e B, demonstrados pelas setas pretas.

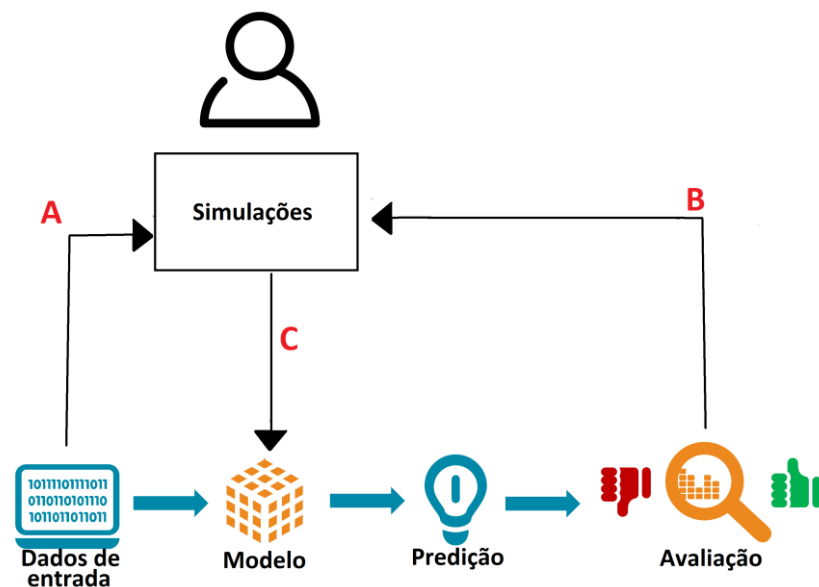


Figura 1: Proposta de pesquisa.

Ou seja, após avaliação final do modelo preditivo, a resposta é apresentada para o educador (seta B) junto com os dados de entrada daquele aluno (seta A). Com esses dados e o resultado, o educador pode alterar uma cópia destes dados e enviar para o modelo realizar a predição sobre essa cópia alterada (seta C). O processo então segue o rumo normal, passando pelas etapas de predição e avaliação do novo resultado gerado com base na cópia dos dados enviados anteriormente.

Com isso, o educador conseguirá comparar os resultados para quantas simulações desejar com o resultado original e, então, chegar a conclusões sobre a qualidade do modelo e as possíveis causas dos resultados. Sendo assim, o educador não apenas passa a ser inserido no processo de decisão, como se torna um potencial avaliador final do modelo preditivo.

Para atingir esse objetivo, precisamos desenvolver um ambiente que permitisse ao educador realizar as simulações sem alterar o modelo. Também foi necessário treinar os modelos preditivos que seriam utilizados em nossos testes e, por fim, avaliar empiricamente o ambiente de simulação com a participação de Educadores de EAD. Para a criação do ambiente seguimos a teoria da Engenharia Semiótica, descrita no Capítulo 2. Já para a criação e todo o processo de treinamento dos modelos preditivos, realizamos um Mapeamento Sistemático da Literatura (MSL) e um conjunto de entrevistas com educadores do EAD. Com isso, extraímos as características consideradas importantes para a identificação de alunos em risco de evasão, e identificamos como a literatura e os pesquisadores apresentam as melhores práticas para o treinamento de modelos preditivos voltados para a identificação de alunos em risco de evasão. Com isso, descobrimos, por exemplo, se os dados demográficos de alunos seriam mais importantes que dados extraídos dos AVAs.

Após esta etapa, iniciamos a implementação do ambiente que permite aos educadores realizar simulações em casos específicos de alunos considerados ou não em risco de evasão. Dessa forma, um educador poderia, por exemplo, selecionar um aluno em risco de evasão, alterar suas características e simular qual seria a predição após esta alteração.

Ao fim da implementação, conduzimos um cenário hipotético com educadores do EAD para que eles pudessem utilizar e relatar a experiência das simulações, através de questionários. Neste cenário, os educadores fizeram simulações em dois modelos preditivos diferentes: uma Árvore de Decisão e uma Rede Neural. Com os resultados colhidos destes questionários, analisamos (1) até que ponto os usuários conseguiram identificar falhas no uso dos modelos e (2) como foi a avaliação dos educadores sobre os resultados dos modelos preditivos.

1.3 ORGANIZAÇÃO

Este trabalho se encontra organizado em sete capítulos. O primeiro capítulo se trata de uma Introdução sobre o tema abordado, a lacuna existente dentro do tema, nossas motivações para abordar o problema e qual nosso objetivo com esta pesquisa. Já o segundo capítulo descreve conceitos que utilizamos neste trabalho e as definições que adotamos como, por exemplo, o próprio termo EAD, evasão, modelos preditivos e explicação em Inteligência Artificial (IA).

No terceiro capítulo apresentamos trabalhos relacionados ao nosso objetivo. Neste capítulo pontuamos os conhecimentos extraídos destes trabalhos e as limitações encontradas após análise dos estudos. O quarto capítulo é onde descrevemos o estudo realizado durante esta pesquisa, incluindo a metodologia adotada, todo o processo do MSL, o conjunto de entrevistas e como estes estudos foram utilizados neste trabalho.

O capítulo cinco, Dropict, contém detalhes sobre o treinamento dos modelos preditivos utilizados na ferramenta, detalhes sobre o Gerador de Cenários e a interface. Além disso, também apresentamos o espaço de design e quais informações utilizamos como base para o desenvolvimento da Dropict.

A avaliação feita pelos educadores sobre a ferramenta é descrita no capítulo seis. Assim, o capítulo seis contém informações desde o recrutamento de educadores para o teste, até nossa análise sobre os dados coletados nesta fase. Por fim, o último capítulo traz nossas conclusões sobre a pesquisa, incluindo nossas limitações e trabalhos futuros.

CAPÍTULO 2 – CONCEITUAÇÃO

Este capítulo apresenta os conceitos necessários para um melhor entendimento sobre os principais conceitos utilizados nessa pesquisa. O primeiro conceito se refere à Educação à Distância, por se tratar do contexto principal onde esta pesquisa está inserida, além de apresentarmos o termo evasão e como utilizamos ele nesta pesquisa. Em seguida apresentamos a Engenharia Semiótica que é utilizada no processo de design do ambiente de simulações.

Como a Inteligência Artificial, os modelos preditivos e suas falhas são um grande ponto de discussão deste trabalho. Por isso, discutimos sobre a Inteligência Artificial, seus modelos preditivos e do que se trata o termo explicação em Inteligência Artificial. Por fim, apresentamos as leis que pautaram parte da crítica levantada no Capítulo de Introdução.

2.1 EDUCAÇÃO À DISTÂNCIA

A Educação à Distância (EAD) é o termo usado para descrever uma modalidade de ensino que utiliza, de alguma forma, meios de comunicação para que o aluno estude e aprenda sem a necessidade de sempre estar presente em um local. Ou seja, o EAD é um modelo de ensino que permite ao aluno acessar, de forma assíncrona, todo ou parte, do conteúdo necessário para o aprendizado (Moore, Dickson-Deane, and Galyen 2011).

Apesar do EAD ser aplicado desde 1970, com universidades aderindo ao uso de e-mails, foi em 1981 que o primeiro curso totalmente assíncrono foi disponibilizado através dos e-mails (Harasim 2000). A partir desse ponto, entre 1980 e 1990, cada vez mais cursos e universidades aderiram ao EAD utilizando, principalmente, computadores disponíveis nas universidades (Harasim 2000).

Porém, foi em 1992, com a invenção da World Wide Web (WWW) que o EAD começou a ganhar mais força, inclusive com novos modelos pedagógicos (Harasim 2000). A chegada da WWW facilitou a expansão do EAD, pois assim passou a ser possível exibir diversas mídias diferentes que alunos poderiam aproveitar quando achassem mais conveniente, em qualquer lugar que tivesse um computador.

Devido a esse grande número de mudanças rápidas, o termo de EAD tem sido misturado e utilizado de diversas formas como, por exemplo, e-Learning (Anderson and Whitelock 2004; Moore, Dickson-Deane, and Galyen 2011). Entretanto, todos esses termos necessitam de alguma forma de tecnologia para que o EAD seja aplicado de forma efetiva, pois em todas as situações referidas os alunos precisam realizar acesso aos conteúdos à distância (Diver and

Martinez 2015; Matukhin and Zhitkova 2015; Moore, Dickson-Deane, and Galyen 2011; Phipps and Merisotis 1999).

Além disso, existem outras nomenclaturas que se referem a categorias de EAD diferentes, como é o caso dos Massive Open Online Course (MOOCs) e do Ensino Híbrido (EH). O primeiro se refere a cursos totalmente online e gratuitos. A ideia base por trás dos MOOCs é fornecer uma possibilidade de ensino, através de vídeo aulas e exercícios realizados totalmente online, para qualquer pessoa com acesso à internet, em qualquer lugar do mundo (Pappano 2012). Já o Ensino Híbrido é uma metodologia recente de EAD que mistura o ensino online à distância com atividades presenciais, com o objetivo de utilizar os lados positivos dos dois modos de ensino (Anderson and Whitelock 2004; Matukhin and Zhitkova 2015).

Apesar dessas modalidades possuírem objetivos, público alvo e metodologias diferentes, Means et al. (2009) demonstrou que não existem diferenças significativas entre o sucesso e evasão no EH e o EAD totalmente online. Então, como esta pesquisa está inserida exatamente no contexto de evasão, utilizamos o termo EAD como um "guarda-chuva" para tratar destas duas modalidades diferentes.

2.2 EVASÃO NA EDUCAÇÃO À DISTÂNCIA

No Brasil, a Comissão Especial de Estudos sobre a Evasão (Andifes, Abruem, and SESu/MEC 1996) definiu, em 1996, três tipos de evasão: evasão do curso, evasão da instituição de ensino e evasão do sistema. A primeira se refere a qualquer forma de abandono do curso, mesmo que o aluno tenha sido desligado pela instituição. A segunda se refere a quando o aluno abandona a instituição de ensino em que se encontrava. Por último, a evasão do sistema ocorre quando o aluno abandona o modelo de ensino (Andifes, Abruem, and SESu/MEC 1996).

De acordo com essas definições, podemos notar que existe uma preocupação em separar o nível de evasão (curso, instituição, sistema). Como este trabalho não se propõe a apresentar novas definições do termo evasão, nós adotamos como evasão aqueles alunos que abandonam seus cursos.

2.3 INTELIGÊNCIA ARTIFICIAL

A Inteligência Artificial é um termo utilizado para descrever a inteligência demonstrada por máquinas ou sistemas. O termo se tornou um campo de pesquisa em 1956, no Dartmouth College (Kline 2011). Desde então, diversos estudos buscaram aperfeiçoar técnicas e algoritmos para criar sistemas inteligentes (Hastie, Tibshirani, and Friedman 2009; Kline 2011; Solomonoff 1985).

Atualmente, devido ao grande número de dados que são gerados todo dia³, técnicas com bases estatísticas foram transformadas em algoritmos para gerar modelos preditivos (Larus et al. 2018) (Hastie, Tibshirani, and Friedman 2009). Existem diversos algoritmos para treinar estes modelos preditivos de formas diferentes como, por exemplo, Regressão Linear, Regressão Logística, Árvore de Decisão, Naive Bayes, entre outras (Alpaydm 2010; Hastie, Tibshirani, and Friedman 2009). Cada um desses algoritmos possui vantagens e desvantagens para diferentes contextos e objetivos (Alpaydm 2010; Hastie, Tibshirani, and Friedman 2009).

Quando um desses modelos preditivos é treinado através de um destes algoritmos, com o objetivo de tomar uma decisão, ele é chamado de modelo preditivo para um sistema de decisão automática (Hastie, Tibshirani, and Friedman 2009; Larus et al. 2018). Por outro lado, quando um modelo preditivo é treinado com o objetivo de classificar um evento ou um conjunto de dados entre um conjunto conhecido de *labels*, chamamos esses modelos de modelos preditivos de classificação (Hastie, Tibshirani, and Friedman 2009; Kotsiantis and Pintelas 2004).

Além dos tipos de algoritmos mais comuns, apresentados anteriormente, os modelos ainda podem diferir em sua forma de treinamento. Podemos ter modelos treinados com dados processados, o qual chamamos de treinamento supervisionado. Outros dois tipos de treinamento são para modelos não supervisionado, ou seja, que são criados com dados de treinamento não classificados, e algoritmos de aprendizado por reforço, que não necessitam de dados de treinamento (Alpaydm 2010; Hastie, Tibshirani, and Friedman 2009).

O primeiro se refere a um tipo de algoritmo que não passa por um treinamento. Esses modelos preditivos recebem apenas entradas e tentam encontrar padrões e semelhanças para classificar os dados de entrada (Hastie, Tibshirani, and Friedman 2009; M. I. Jordan and Bishop 2004). O segundo tipo se refere a algoritmos que precisam executar ações e, após a execução, recebem um retorno como “certo” ou “errado”. A partir de seus erros, o modelo preditivo tenta aprender para não errar mais (Bertsekas 2012; Hastie, Tibshirani, and Friedman 2009).

Como nosso trabalho não lida com os algoritmos que permitem a criação de modelos preditivos não-supervisionados e modelos preditivos criados a partir do aprendizado por reforço, não entraremos em mais detalhes sobre eles. Por outro lado, os modelos preditivos treinados de forma supervisionada estão em nossa pesquisa e, por isso, vamos explicar seu processo, conforme apresenta a Figura 2.

A etapa inicial consiste em dados que possam ser usados para o treinamento do algoritmo. De posse destes dados, deve-se então escolher um dos algoritmos de treinamento

³ <https://www.forbes.com/sites/bernardmarr/2018/05/21/how-much-data-do-we-create-every-day-the-mind-blowing-stats-everyone-should-read/#35cc56da60ba>

supervisionado. Ao utilizar os dados de treinamento no algoritmo, é gerado o que chamamos de modelo preditivo. Esses modelos são, então, capazes de realizar previsões baseados em dados de entrada que nunca foram vistos durante seu treinamento.

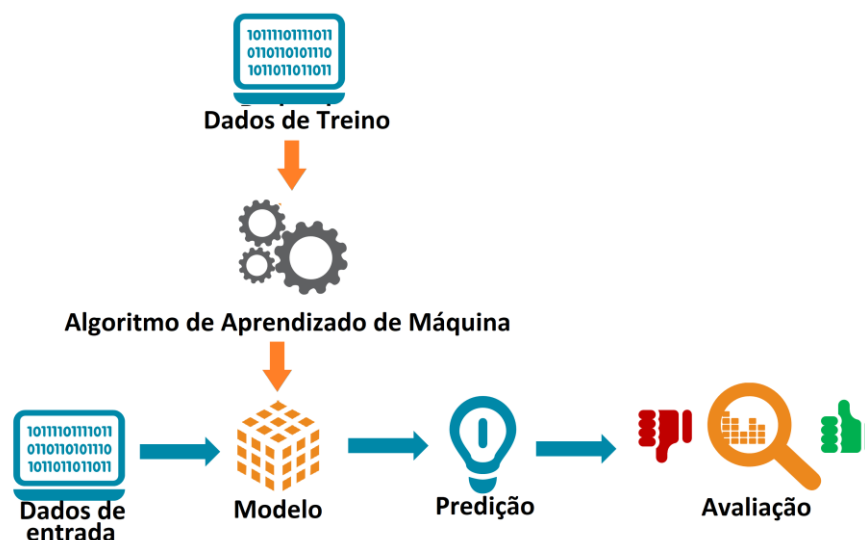


Figura 2: Processo para treinamento e uso de um modelo preditivo supervisionado

2.4 EXPLICAÇÃO EM INTELIGÊNCIA ARTIFICIAL

O termo *Explainable Artificial Intelligence* (XAI) está relacionado com o quão bem uma IA consegue transparecer seu funcionamento, ou seja, o quanto uma IA consegue ser interpretável; o quanto os usuários conseguem entender sobre o modelo preditivo ao utilizá-lo; o quanto o resultado obtido da IA é explicável (Dosilovic, Brcic, and Hlupic 2018; Miller 2017). Como o termo “explicação” pode ser um termo muito abrangente com significados profundos (Miller 2017), vamos definir a explicação apenas no contexto de IA, o que ainda pode ser desafiador.

Segundo Miller (2017) a explicação no contexto de sistemas inteligentes pode ser separada em dois tipos de explicações: (1) as explicações sobre a funcionalidade dos sistemas e (2) as explicações sobre as decisões tomadas pelo sistema. A primeira se refere a lógica do sistema, como sua árvore de decisão, modelos preditivos das regras predefinidas, estruturas de classificação e afins. Já o segundo tipo de explicação se refere as causas que podem ter levado o modelo preditivo a tomar aquela decisão, por exemplo, peso das características. Kim e Routledge (2018) ainda descrevem que as explicações podem ser separadas de acordo com o momento em relação ao processo da decisão do modelo preditivo.

Assim, existem as explicações *ex ante*, que representam explicações sobre processos ocorridos antes que a decisão seja feita, e também existem as explicações *ex post*, que representam explicações sobre processos que ocorreram após a decisão do modelo preditivo

(Kim and Routledge 2018). Para o nosso trabalho, a ferramenta de simulação proposta tem o intuito de trazer a possibilidade de questionamento e investigação dos modelos preditivos, o que pode ser considerado uma tentativa para a explicação ex post.

2.4.1 MODELOS PREDITIVOS EXPLICÁVEIS

Um dos fatores que pode influenciar diretamente na explicação das IAs é a escolha do algoritmo utilizado para o treinamento do modelo preditivo. Existem algoritmos como, Árvore de Decisão, que conseguem até mesmo gerar o processo de decisão completo de um modelo treinado por este algoritmo. Por outro lado, também existem algoritmos que não conseguimos extrair nem mesmo o processo de decisão durante o treinamento, como é o caso de algoritmos para criar Redes Neurais (Holzinger et al. 2017). Assim, chamamos o primeiro tipo de modelo descrito como modelos preditivos caixa-branca. Enquanto àqueles modelos dos quais não conseguimos extrair o processo de decisão, são classificados como modelos preditivos caixa-preta (Holzinger et al. 2017).

Como nós conseguimos identificar as motivações por trás das predições destes modelos preditivos caixa-branca, dizemos que eles representam modelos preditivos de fácil interpretação. Já os modelos caixa-preta, apesar de muitas vezes possuírem resultados estatísticos melhores, eles ainda pecam sobre o fornecimento de “explicações” que levaram o modelo preditivo àquele resultado. Por isso, dizemos que estes modelos preditivos caixa-preta representam modelos de difícil interpretação (Holzinger et al. 2017; Miller 2017).

Essa falta de explicação pode, como Joh (2016) discutiu, esconder resultados baseados em vieses e preconceitos, o que pode ser uma falha extremamente crítica. Além disso, como os modelos preditivos não conseguem acertar sempre, e essas decisões estão impactando cada vez mais em nossas vidas, é importante entender que características dos dados de entrada levaram os modelos aos seus resultados para que os usuários questionem e descubram quando uma predição é falha.

2.4.2 DIREITO À EXPLICAÇÃO EM IA

O direito à explicação voltado para IAs pode ser entendido como um direito à transparência sobre a motivação por trás das decisões dos modelos preditivos e, principalmente, sobre o tratamento com os dados pessoais utilizados nestes casos (Monteiro 2018; Union 2018). Esse direito se faz cada vez mais importante devido a quantidade de decisões que são tomadas por modelos preditivos, além dos problemas citados por Joh (2016) como, por exemplo, vieses culturais e decisões preconceituosas.

A GDPR torna este direito claro em sua documentação (Union 2018), apesar de alguns autores (Wachter, Mittelstadt, and Floridi 2017) afirmarem que é um direito limitado à informações sobre a lógica envolvida, assim como o significado e as consequências previstas pela tomada de decisão automatizada. Por outro lado, a LPD-Br não possui esse direito explícito (Monteiro 2018). Entretanto, mesmo que não esteja explicitamente escrito, esses tipos de direito afetarão amplamente a forma como utilizamos os modelos preditivos (Albrecht 2016).

Por isso, é cada vez mais importante abordar e pesquisar sobre o tema. Esta pesquisa, por exemplo, pode ser vista como uma oportunidade futura para permitir que pessoas sem conhecimento técnico sobre o funcionamento de IAs possam, de alguma forma, questionar e encontrar uma explicação ex post para predições de um determinado modelo preditivo.

2.5 ENGENHARIA SEMIÓTICA

Precisamos definir como será a implementação deste protótipo, pois nossa pesquisa envolve um protótipo para que os educadores possam interagir com os modelos preditivos. Dessa forma, fundamentamos nossas decisões de interação com base na Engenharia Semiótica para os processos interativos existentes neste protótipo.

A Engenharia Semiótica (ES), criada por volta de 1990 (Clarisse S. de Souza 1993), surgiu para apoiar o design de interfaces. Como a ES enxerga o processo interativo como uma comunicação entre os desenvolvedores e os usuários, esse apoio ocorre através de métodos que possuem o objetivo de identificar a mensagem, chamada de metacomunicação, que os desenvolvedores de um sistema desejam passar para os usuários daquele sistema (Clarisse Sieckenius de Souza 2005). Por isso, para avaliar o processo interativo existente na ferramenta, utilizamos a ES (Clarisse Sieckenius de Souza 2005).

Neste processo de metacomunicação, a ES lida com os desenvolvedores, usuários e o sistema. Onde, desenvolvedores se comportam como os emissores da mensagem, usuários se tornam os receptores e o sistema se comporta como o meio pelo qual a mensagem é recebida pelos usuários (Clarisse Sieckenius de Souza 2005). O diferencial desta metamensagem é que o emissor (desenvolvedores) realiza a mensagem apenas durante o processo de design do sistema (Clarisse Sieckenius de Souza 2005). Com esta visão, conseguimos definir nosso emissor, contexto de comunicação, o próprio receptor, os códigos de comunicação e os canais de comunicação.

Os detalhes sobre como aplicamos esta teoria no desenvolvimento do protótipo pode ser visto no Capítulo 5. Lá apresentamos todas as etapas da ES aplicadas ao nosso contexto de uso com os educadores.

CAPÍTULO 3 – TRABALHOS RELACIONADOS

Neste capítulo são apresentados trabalhos que envolvem a inserção de educadores no processo decisivo gerado por modelos preditivos treinados para a identificação de alunos em risco de evasão. Aqui estão pesquisas encontradas por buscas exploratórias em diferentes bases de busca. Em cada trabalho descrevemos as limitações encontradas e quais informações conseguimos extrair.

Existem diversos trabalhos com único foco na predição de alunos em risco de evasão na EAD, como pode ser observado no resultado de nosso MSL, no capítulo sobre os estudos realizados. Entretanto, os trabalhos que consideramos mais próximos ao proposto em nossa pesquisa estão relacionados com a união entre este tipo de predição e a experiência dos educadores.

Neste contexto, existem trabalhos focados em sistemas, chamados *Early Warning System* (EWS), que se propõe a alertar usuários de potenciais problemas, antes que ocorram (Frazelle and Barton 2006; Frazelle and Nagel 2015). Entre estes trabalhos, Knowles (2015) demonstra o uso de Mineração de Dados na construção de modelos para EWS que se propõe ao alerta de alunos em risco de evasão. Sua pesquisa reforça a importância da relação entre os dados e o contexto onde a análise destes dados ocorrerá.

Knowles (2015) aponta que os dados e impacto causado por seu trabalho tem, como principal origem e alvo, o estado norte americano chamado Wisconsin. Knowles (2015) conduziu a pesquisa analisando os atributos e as técnicas de Mineração de Dados que deveriam ser escolhidas. Ao final, o trabalho não apresenta os modelos inseridos em algum EWS. Porém, sua pesquisa reforça o cuidado com os dados, sua origem e onde estes dados serão aplicados, além de apontar os fatores de risco encontrados em sua análise.

Este tipo de trabalho, como o de Knowles (2015), reforça a motivação por trás dos cuidados que tivemos ao realizar um Mapeamento Sistemático da Literatura, em conjunto com entrevistas, para definir os atributos que deveríamos utilizar na construções de nossos modelos preditivos. Outra pesquisa com a preocupação do contexto e dos dados, é o trabalho conduzido por Lee e Chung (2019). Nele, os autores estudam diversas técnicas de Aprendizado de Máquina para o treinamento de modelos preditivos com o intuito de melhorar a performance da predição de evasão em EWS. Nesse sentido, eles demonstram a preocupação com a falta de balanceamento dos dados e explicitam sua preocupação com a educação na Coreia do Sul, onde o estudo foi conduzido.

Outros pesquisadores focam seu trabalho no desenvolvimento do próprio EWS, voltando para a predição de evasão dos alunos, seja na EAD ou no ensino presencial. Ortigosa e colegas (2019), por exemplo, realizaram uma pesquisa sobre o desenvolvimento de um EWS que tinha como foco a predição de evasão e a passagem dessa informação para os usuários desses sistemas (educadores). Para isso, eles desenvolveram uma aplicação composta por 4 componentes. O primeiro era responsável por extrair e realizar pré-processamento nos dados de entrada. O segundo módulo era responsável por gerar diferentes modelos preditivos com os dados processados pelo primeiro. Já o terceiro módulo tinha a finalidade de avaliar os modelos e os atributos mais impactantes para as predições desses modelos. Por último, um módulo responsável por apresentar esses dados aos usuários.

Como a explicação por trás da predição era um requisito importante para os autores, eles optaram por utilizar apenas modelos caixa branca, alegando que esses requisitos os impediam de utilizarem outros tipos de modelos. Essa escolha foi feita mesmo apontando modelos "caixa preta" com resultados melhores.

Após análise do trabalho, vemos que as principais vantagens do EWS proposto pelos autores está na possibilidade de inserção de notas manuais que podem afetar a predição e nas informações dispostas para os usuários, informando os atributos mais relevantes para os resultados. Apesar de demonstrar um resultado interessante, o EWS não permite ao usuário descobrir predições falhas. Então, quando os contextos usados para treinar o modelo não refletirem mais a realidade vivida pela IE, os usuários da aplicação não teriam como perceber essa defasagem dos modelos preditivos.

O problema é que os usuários não possuem uma forma de questionar a predição para tentar identificar esses erros. Além disso, para que a explicação do sistema funcione, é necessário a utilização de modelos simbólicos. O que, como discutido pelos próprios autores, não representa os melhores modelos para predição.

Outro trabalho que também se preocupa, não só com a predição de evasão dos alunos, mas também em como apresentar esse resultado para os usuários desse tipo de sistema, é a pesquisa conduzida por Wolff e seus colegas (2014). Eles utilizaram uma combinação de quatro modelos treinados por três algoritmos para realizar a predição. Dois desses modelos utilizaram o algoritmo *k Nearest Neighbors* (k-NN) e são utilizados para agrupar alunos com dados similares em diferentes conjuntos. Os autores utilizaram dois para que um k-NN utilizasse apenas dados demográficos, enquanto o outro modelo apenas dados do AVA. Os outros dois modelos utilizaram algoritmos diferentes. Um algoritmo consiste de uma Árvore de Regressão e Classificação (CART) e o outro de uma Rede Bayesiana. Ambos utilizados para a predição

dos alunos, tanto com os dados demográficos, quanto com os dados do AVA como, por exemplo, tempo de acesso na plataforma. Então, a decisão final se um aluno irá evadir é decidida por votação entre os resultados desses algoritmos. Ou seja, o que a maioria dos resultados disser, será considerado no final.

A interface da ferramenta desenvolvida pelos autores apresenta algumas estatísticas dos dados e, até mesmo, a disposição dos conjuntos de alunos semelhantes identificados pelo k-NN, como mostra a Figura 3. Além dessas informações, nota-se, na Figura 3, uma coluna chamada *Justification*. Essa coluna, aparentemente, tem o objetivo de justificar a predição de cada aluno. Porém, em nenhum momento, os autores discutem sobre esta coluna e como ela é construída.



Figura 3: Interface do EWS desenvolvido por Wolff e colegas

Pela análise do trabalho, os autores informam que o trabalho ainda não estava completo, porém acreditavam que o retorno visual com as estatísticas dos dados e os conjuntos de alunos semelhantes seria um começo promissor para apoiar as decisões de resgate dos alunos em risco de evasão, sem ter realizado testes com usuários. Por isso, ainda fica a dúvida se a apresentação dessa ferramenta, apenas com os dados estatísticos e o conjunto de usuários, seria o suficiente para que os educadores encontrem as motivações por trás das predições.

Outro ponto que vale destacar sobre o trabalho dos autores é a utilização dos quatro modelos preditivos para tentar minimizar predições equivocadas. Como não foi demonstrada nenhuma comparação estatística entre os resultados individuais e em conjunto, também não

conseguimos saber se essa estratégia é, de fato, efetiva. Ainda assim, mesmo se houver uma redução de predições erradas, eventualmente, os erros ainda surgirão e os modelos poderão ficar atrasados e parar de refletir a realidade encontrada onde a ferramenta possa ser aplicada. Os usuários, entretanto, não possuem uma forma para avaliar esses resultados errados. Ou seja, ainda sofre do mesmo problema encontrado na pesquisa de Ortigosa e colegas (2019).

Hu e colegas (2014) também construíram um EWS, porém seu intuito era prever o desempenho dos alunos. Outra diferença que o trabalho dos autores apresenta é o fato de terem criado duas interfaces diferentes, como mostram as Figuras 4 e 5. Enquanto a Figura 4 apresenta uma interface para os alunos, a Figura 5 apresenta outra interface para os educadores.



Figura 4: Interface do EWS para os alunos, desenvolvida por Hu e colegas



Figura 5: Interface do EWS para os educadores, desenvolvida por Hu e colegas

De acordo com o trabalho de Hu e colegas (2014), é importante utilizar um EWS também para os alunos. Em seu trabalho, os alunos conseguem comparar seus desempenhos com a média e os valores de melhor e pior caso de outros alunos, sem ter acesso direto a correspondência desses dados, como mostra a Figura 4. Ou seja, sem saber de quais alunos, individualmente, eram os dados. Já a interface apresentada para os educadores, como mostra a Figura 5, possibilita a visualização individual dos alunos e de dados gerais de uma determinada classe.

Para avaliar seu EWS, os autores realizaram um questionário com perguntas como, "A interface é fácil de usar?", "É fácil encontrar a informação necessária?", "É fácil aprender a utilizar", entre outras. Todas as perguntas foram respondidas de forma objetiva, utilizando a escala Likert. Ao final, os resultados obtidos foram positivos (Hu, Lo, and Shih 2014).

Embora demonstre a preocupação com uma interface para os alunos, o que não foi discutido nos trabalhos anteriores, Hu e colegas (2014) também apresentam uma ferramenta de análise de dados com gráficos. Dessa forma, tanto os educadores quanto os alunos, não conseguem questionar os motivos que levam à performance prevista nos casos encontrados. Um aluno poderia, inclusive, alterar toda sua forma de estudo baseando-se no resultado previsto enquanto, na verdade, esse resultado poderia estar errado.

Um sistema que não foi classificado pelos autores como um EWS, mas que auxilia na tentativa de inserir os educadores nesse processo de decisão, é o trabalho de Chen e colegas

(2017). O trabalho deles propõe uma ferramenta para análise dos dados que se encontram em um AVA. No sistema dos autores, a interface apresenta grande gráficos e desenhos que buscam resumir a quantidade de dados gerados por um AVA, como mostra a Figura 6.

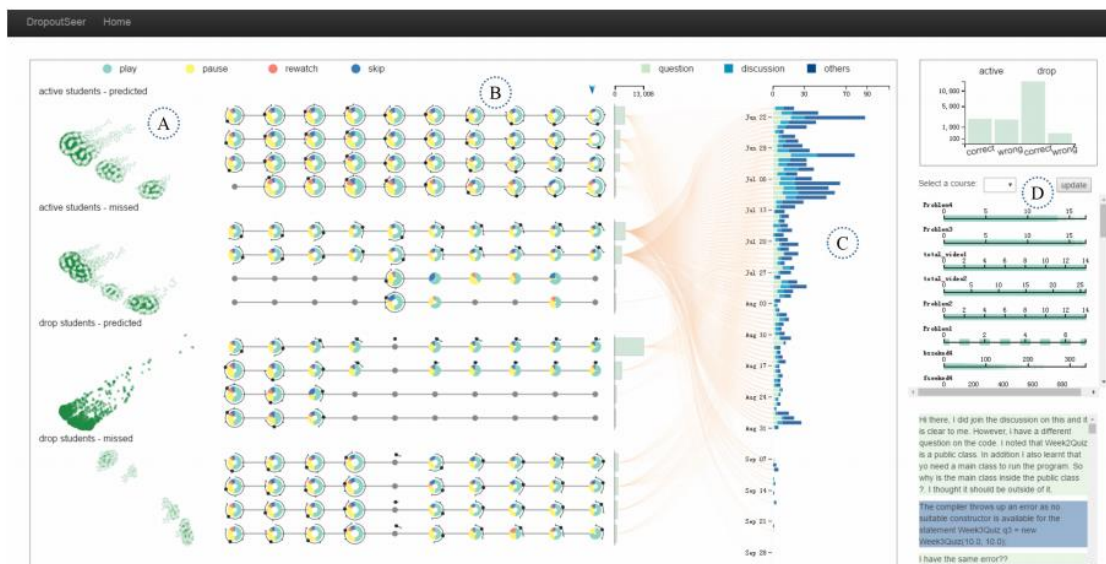


Figura 6: Interface da ferramenta proposta por Chen e colegas

O intuito é deixar os educadores utilizarem essa visualização para tirarem suas próprias conclusões. Entretanto, além de visualizar os dados, os educadores também se deparam com predições e associações feitas com algoritmos de Aprendizado de Máquina e Mineração de Dados. Ou seja, os educadores possuem predições e podem visualizar os dados que foram usados nestas predições. Essa solução pode ser útil para que estes usuários consigam buscar explicações para os resultados. Porém, não permitirá que eles consigam testar hipóteses no intuito de validar seus pensamentos. Com a ferramenta de Chen e seus colegas (2017), os educadores devem decidir se confiam ou não nos resultados preditivos, enquanto observam os dados usados para a entrada das predições.

Nossa pesquisa também irá exibir os dados de entrada, utilizados nas previsões, para os educadores. Entretanto, nós adicionamos o fator das simulações justamente para que os educadores consigam validar seus pensamentos, sem que precisem, necessariamente, confiar apenas no que estão vendo naquele momento. Ou seja, os educadores podem testar questões como "e se esse atributo fosse diferente?". Contudo, o trabalho dos autores citados acima demonstra que, após entrevistas sobre a ferramenta, educadores gostaram da possibilidade de visualizar essas informações de entrada.

Kotsiantis e Pintelas (2004) também apresentam um trabalho relacionado à predição de alunos em risco de evasão na EAD. A diferença entre seu trabalho e os outros discutidos

anteriormente é que a ferramenta dos autores não possui um algoritmo ou modelo predefinido para a predição. Eles construíram uma ferramenta que tivesse diferentes algoritmos e que fosse capaz de auxiliar os educadores do EAD na escolha de qual algoritmo é melhor para o treinamento de um modelo preditivo. Sua ferramenta é composta de 6 componentes: (1) um módulo com os algoritmos de aprendizado de máquina e um guia para auxílio do educador, (2) algoritmos para realizar regras de associação, (3) um componente para realizar e apresentar estatísticas sobre os dados, (4) outros algoritmos utilizados para seleção dos melhores atributos da base de dados informada, (5) um conjunto de métodos para balancear a base de dados, caso necessário e, por último, (6) outro módulo, utilizado para exportar o modelo treinado em uma página de uso do educador.

O objetivo principal dos autores é fornecer um meio para que os educadores consigam participar do treinamento dos modelos preditivos. Com a ferramenta de Kotsiantis e Pintelas (2004), os usuários são responsáveis por escolher os atributos e o tipo de algoritmo que serão utilizados para a criação do modelo preditivo. Após este treinamento, a ferramenta gera uma interface HTML local para que o usuário utilize o modelo que foi treinado a partir de suas escolhas. Nessa interface, o usuário se depara com atributos dos alunos, os quais o educador deve selecionar os valores. Após isso, o usuário pode verificar qual a predição para os valores escolhidos nos atributos, como mostra a Figura 7.

The screenshot shows a web browser window titled "D:\SOTOS\working papers\DROP-OUT-HTML - Microsoft Internet Explorer". The address bar shows "D:\SOTOS\working papers\DROP-OUT-HTML". The main content area has the heading "PREDICTION DROP-OUT TOOL". Below the heading is a form with two columns of input fields. The left column contains: Sex (male), Age (>=32), Marital status (single), Children (0), Occupation type (part-time), and Computer Literacy (yes). The right column contains: Job associated with computer (no), FTOF-1 (yes), WRI-1 (mark<5), FTOF-2 (no), and WRI-2 (-). Below the form are two buttons: "Predict" and "Clear". At the bottom of the form, it says "Probability of drop-out = 95.21 %".

Figura 7: Interface de Kotsiantis e Pintelas para uso do modelo preditivo treinado

A pesquisa dos autores estava mais envolvida com a possibilidade de facilitar a criação de modelos preditivos para usuários e o uso de muitos atributos para a predição de evasão na

EAD que, de acordo com eles, era algo novo em 2004, do que o entendimento e questionamento desses resultados. A forma como os educadores poderiam entender esses resultados era através de estatísticas sobre os dados e ajuda antes da criação do modelo. Após o treinamento, os educadores não tinham opção além de usar aquele modelo ou tentar a criação de um novo. Entretanto, esse tipo de trabalho, além de nos mostrar que essa tentativa de inserir os educadores no processo decisivo dos modelos preditivos ocorre desde 2004, também reforça a necessidade de soluções que permitam aos educadores realizar questionamentos e testes em resultados de modelos preditivos.

O trabalho de Kotsiantis e Pintelas (2004) demonstra uma ideia parecida com a possibilidade de simular atributos e verificar suas predições. Porém, se um educador realizar, por exemplo, seis predições com cenários diferentes, este educador pode se perder em quais atributos fizeram diferença para a mudança dos resultados obtidos. Por isso, em nossa ferramenta, o educador terá à sua disposição todas as simulações que ele realizou.

Por fim, outro trabalho que apresenta pesquisas que inserem os educadores na criação dos modelos preditivos, é o trabalho de Nagrecha, Dillon, e Chawla (2017). Estes pesquisadores discutiram sobre o tema de interpretabilidade em modelos preditivos. Seu objetivo principal era investigar como o processo dos modelos preditivos poderiam ser interpretáveis no contexto de MOOCs.

Para isso, Nagrecha, Dillon, e Chawla (2017) desenvolveram um fluxo em que as predições ocorriam semanalmente e, ao juntar as predições semanais com os dados de entrada utilizados em cada uma dessas predições, analisar em conjunto e realizar cálculos probabilísticos para definir a importância de cada atributo na predição final. De acordo com os autores, uma predição interpretável começa com atributos interpretáveis. Sendo assim, se eles isolarem os atributos que, estatisticamente, são impactantes para o resultado da predição, então eles conseguiriam apresentar uma motivação para aquele resultado. As comparações semanais seriam para reforçar apresentando a diferença entre estas semanas e como a importância dos atributos variou neste tempo.

Apesar de ser um trabalho com ótimas contribuições, principalmente nas questões de interpretabilidade, os educadores ainda estão reféns do que os modelos apresentam, na proposta desenvolvida pelos autores. Da mesma forma que os outros trabalhos discutidos acima, os educadores não conseguiriam testar hipóteses para verificar se seus pensamentos estão corretos. Eles só poderiam se basear nos resultados obtidos a cada semana.

Por esse motivo, diferente dos trabalhos encontrados e apresentados aqui, nossa pesquisa busca permitir que os educadores possam questionar e avaliar os resultados das

previsões. Em nosso estudo, o educador não participa da criação do modelo, porém ele se torna o avaliador final daquele modelo preditivo.

CAPÍTULO 4 – ESTUDO REALIZADO

Como Mertens (2005) apontam, um paradigma de pesquisa pode ser visto como uma forma, ou visão, para se coletar e analisar dados com o objetivo de entender, prever ou descrever fenômenos. Porém, um paradigma de pesquisa pode ir muito além desta definição. Mackenzie e Knipe (2006), no intuito de auxiliar pesquisadores na organização de paradigmas e metodologias de pesquisa, afirmam que o paradigma adotado influencia diretamente na metodologia de pesquisa, na condução da pesquisa e, principalmente, no objetivo almejado pelo pesquisador. Assim, seguindo os pensamentos de Mackenzie e Knipe (2006), primeiro nós precisamos apresentar o paradigma adotado para depois avaliar a melhor metodologia para conduzir a pesquisa.

4.1 PARADIGMA

A “escolha” do paradigma que um pesquisador segue pode estar mais relacionada com a forma do pesquisador pensar, suas motivações, suas intenções e capacidades, do que com sua vontade (Mackenzie and Knipe 2006). Por isso, nós vamos primeiro discutir sobre os quatro principais paradigmas de pesquisa e ao final desta seção vamos justificar nossa “escolha”. Para Mackenzie e Knipe (2006), existem quatro paradigmas que são mais adotados durante as pesquisas: (1) positivista e pós positivista, (2) construtivista, (3) transformativo, e (4) pragmático.

Segundo Mertens (2005) e Creswell (2003), o paradigma positivista tem suas origens com o pensamento de Aristóteles, onde dados empíricos e probabilísticos possuem muito valor. Assim, pesquisadores positivistas, ou pós positivistas, tendem a conduzir pesquisas quantitativas, pois trabalham com conceitos e regras bem definidas e buscam explicar suas pesquisas da mesma forma (Mackenzie and Knipe 2006).

Já o paradigma construtivista está associado aos pesquisadores que acreditam na construção social e procuram entender a experiência humana (Mackenzie and Knipe 2006; Mertens 2005). Como os pesquisadores construtivistas colocam alto valor na experiência e visão humana, eles estão mais propensos a utilização de métodos qualitativos (Creswell 2003). Porém, Mackenzie e Knipe (2006) apontam que também é possível adotar metodologias quantitativas para acrescentar à pesquisa.

Mertens (2005) colocam o surgimento do paradigma transformativo, entre 1980 e 1990, como uma necessidade sentida por pesquisadores que não estavam satisfeitos com a visão construtivista que, segundo Creswell (2003), parecia não abordar causas que poderiam influenciar e afetar a vida das pessoas, principalmente em relação a injustiças sociais. Assim, o

paradigma transformativo possui intenção de transformar a vida das pessoas, os pesquisadores dessa visão também recorrem a métodos qualitativos e quantitativos, principalmente para entender a diversidade de valores (Mackenzie and Knipe 2006).

Por último, o paradigma pragmático, também na definição de Creswell (2003), é visto como um paradigma em que o pesquisador busca a resposta para um problema central e bem definido. No pragmatismo, os dados e análises possuem o objetivo de prover *insights* e testar os resultados (Mackenzie and Knipe 2006). Por isso, também podem se beneficiar tanto de métodos qualitativos, quanto quantitativos, ou mesmo ambos.

Como nosso principal objetivo é a criação da ferramenta que permita aos educadores realizar interações e questionamentos de modelos preditivos treinados para detectar evasão de alunos na EAD, então nossa pesquisa está relacionada com a transformação na vida de pessoas envolvidas na EAD. Por esse motivo, nossa visão para essa pesquisa é baseada no paradigma transformativo.

4.2 METODOLOGIA

Dado nosso objetivo principal com essa pesquisa e o paradigma adotado, foi necessário validar todo o procedimento da pesquisa com o Comitê de Ética da Universidade Federal Fluminense⁴. Para a avaliação do Comitê, foi necessário apresentar uma descrição do projeto, perfil dos participantes e possíveis impactos positivos e negativos. Após validação, o projeto foi aprovado sob o parecer número 3.381.785.

A metodologia de pesquisa escolhida se baseia, fortemente, nas definições de Creswell (2003). Em seu trabalho, ele apresenta 3 abordagens como metodologias de pesquisa: (1) qualitativa, (2) quantitativa e (3) metodologia mista. A primeira diz respeito a estudos que buscam o conhecimento através da experiência, significado social, história e perspectiva de pessoas, onde todos os relatos possuem importância e não só o que diz a maioria (Creswell 2003). As pesquisas quantitativas, por outro lado, buscam adquirir o conhecimento através de hipóteses bem formuladas, medidas, observações e redução das condições em variáveis para que possam ser testadas (Creswell 2003). Por fim, a pesquisa mista consiste na adoção da mistura de ambas as metodologias. Os dados são coletados e analisados tanto por estratégias qualitativas, quanto estratégias quantitativas. Isso permite que o pesquisador possa comparar os resultados e entender melhor sobre o assunto pesquisado (Creswell 2003).

⁴ <http://cep.uff.br/>

Como nós precisamos entender sobre as características importantes para a identificação de alunos em risco de evasão na EAD, optamos por realizar um MSL com este objetivo. Entretanto, devido a importância do contexto onde esta identificação ocorre (Joh 2016), também foi preciso realizar entrevistas com educadores do EAD. Por isso, a metodologia mista foi adotada.

Então, a primeira etapa consiste de um MSL para entender quais características mais influenciam o abandono na EAD, ou seja, que atributos os modelos preditivos utilizam para suas predições. Em paralelo ao MSL ocorre a segunda etapa, que consiste de entrevistas com educadores e alunos com experiências na EAD para verificar e entender a visão deles sobre os fatores que levam ao abandono nesta modalidade de ensino.

As informações extraídas nas duas primeiras etapas são comparadas e avaliadas em uma terceira etapa. O intuito é descobrir se os resultados encontrados no MSL refletem a experiência vivida por professores e alunos em uma EAD atual, no Brasil.

As próximas duas etapas maiores consistem na implementação da ferramenta Dropict e os testes com a ferramenta, respectivamente. Como discutido no capítulo de Introdução, a ferramenta possui três 3 partes principais: a interface, o simulador de cenários e o modelo preditivo. Dito isso, para desenvolver os modelos preditivos que utilizamos, precisamos de uma base de dados de cursos superiores EAD, definir os atributos utilizados para o treinamento e quais algoritmos serão escolhidos para os treinamentos dos modelos preditivos.

Uma das formas conhecidas para a escolha dos atributos utilizados no treinamento do modelo preditivo, é através da Seleção de Características (Dash and Liu 1997; V. Kumar and Minz 2014; Langley 1994). Porém, optamos por fazer a seleção dos atributos baseados no histórico de trabalhos sobre a predição de evasão na EAD (MSL) e a experiência de educadores do EAD (entrevistas). Fizemos esta escolha para garantir que o contexto onde realizaremos as avaliações finais seja similar ao contexto treinado pelo modelo preditivo. Garantir que os contextos de treino e avaliações sejam similar, pode auxiliar contra o viés cultural presente nas bases (Joh 2016). Além disso, o fator principal para essa decisão é baseado no princípio que, para chegar ao nosso objetivo, precisamos permitir que os educadores simulem atributos conhecidos por eles, e não propor melhorias nas acurácias das predições.

Já a base de dados e os algoritmos escolhidos, bem como as motivações por trás de suas escolhas, são discutidas no Capítulo 5. Por fim, fizemos a seleção dos educadores para realização de análise sobre a ferramenta e as simulações. Esta última etapa é discutida no Capítulo 6.

4.3 MAPEAMENTO SISTEMÁTICO DA LITERATURA

Um Mapeamento Sistemático da Literatura (MSL) tem como principal objetivo adquirir uma visão geral de uma área de pesquisa (Cooper 2016; Dermeval, Coelho, and Bittencourt 2019; Petersen, Feldt, and Mujtaba 2008). Assim é possível, não só eliminar possíveis vieses que o pesquisador possa ter, como também extrair resultados quantitativos sobre abordagens, métodos e resultados obtidos em um conjunto de pesquisas (Cooper 2016). Para atingir esse objetivo é necessário seguir um processo estruturado, como mostra a Figura 8 (Petersen, Feldt, and Mujtaba 2008).

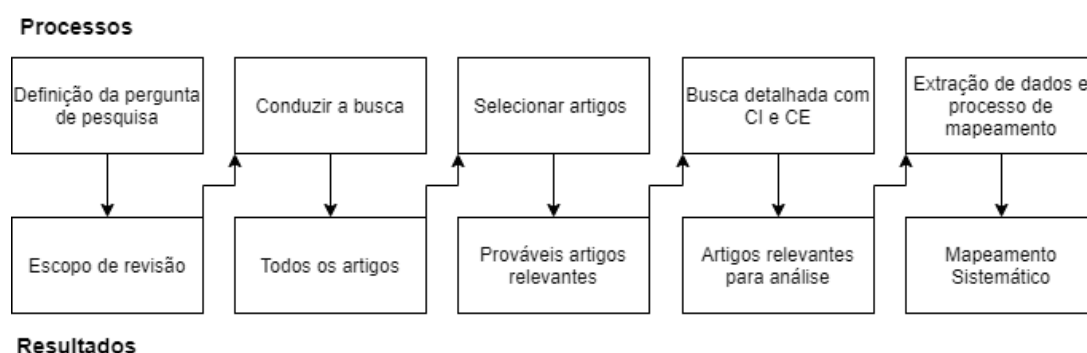


Figura 8: Processo de um MSL traduzido de Petersen, Feldt, e Mujtaba (2008)

Na Figura 8 é possível observar todo o processo de um MSL: (1) inicia-se com a definição da questão de pesquisa. Nessa etapa 1 é onde a lógica de busca será montada, baseando-se na questão de pesquisa que foi definida. O próximo passo é (2) a pesquisa nas bases de busca indexadas utilizando a lógica de busca que foi definida no passo anterior. Após isso, (3) todos os artigos são avaliados por algum método de seleção inicial para que apenas os artigos relevantes sobre a questão de pesquisa levantada, passem para o próximo passo. Com os artigos relevantes selecionados, é preciso (4) filtrar novamente e garantir que esses artigos possuem relação com o tema pesquisado. Para isso, é comum que o resumo de cada um dos artigos seja lido para que o pesquisador possa garantir quais trabalhos refletem ou não o tema de pesquisa (Dermeval, Coelho, and Bittencourt 2019). Por último, (5) os artigos que se mantiveram selecionados são estudados para extrair as informações.

4.3.1 STRING DE BUSCA

A *string* de busca é um componente muito importante para um bom mapeamento sistemático (Petersen, Feldt, and Mujtaba 2008). É através da string de busca que os artigos poderão ou não aparecer no mapeamento sistemático, pois ela é utilizada nos campos de busca das conferências e das bases de busca indexadas (Petersen, Feldt, and Mujtaba 2008). Assim, se a string de busca

não representar a questão de pesquisa de forma eficiente, artigos importantes podem não aparecer no mapeamento sistemático.

Nossa string foi definida para mapear que características influenciam o abandono de alunos na EAD e como os autores consideram os atributos utilizados para os treinamentos de seus modelos preditivos. Assim, em linhas gerais, queremos descobrir como os modelos preditivos para evasão de alunos na EAD são treinados.

Como discutido no Capítulo 2, o EAD possui diversos termos e estes termos podem ser utilizados de forma equivocada. Por isso, nossa string de busca precisa ter os diversos termos para EAD e, ainda, a palavra “evasão” e suas variações, pois é o principal termo do contexto estudado nesta pesquisa.

Assim, a lógica de busca ficou definida como: No título, resumo ou nas palavras-chave, deve conter (((*"blended"* OR *"distance"* OR *"open"*) AND (*"learning"* OR *"education"*)) OR *"e-learning"* OR *"MOOC"*) AND (*"dropout"* OR *"drop out"* OR *"drop-out"*))

Essa lógica se divide em dois lados principais que são separados pelo AND mais exterior: o primeiro lado diz respeito às nomenclaturas utilizadas para o EAD e o segundo lado diz respeito ao abandono e suas variações. No primeiro lado, temos ainda um fator importante: os termos de EAD “blended”, “distance” e “open” devem estar acompanhados de “learning” ou “education”. Isso ajuda a garantir que serão trabalhos mais relacionados com o ensino e também garante que estamos inserindo tanto trabalhos de aprendizado quanto de educação.

É importante destacar que optamos por realizar o MSL somente em inglês, pois o objetivo é obter uma visão geral sobre como os atributos são utilizados e escolhidos pela Computação. Então, como Dermeval, Coelho, e Bittencourt (2019) apontam, um MSL que se limite apenas a língua inglesa é menos suscetível a um possível viés de alguma determinada região. Além disso, para organizar todo processo dos trabalhos, nós utilizamos o sistema de planilhas do pacote *Libre Office*⁵.

4.3.2 MECANISMOS DE BUSCA ACADÊMICA

A lógica de busca precisa ser aplicada em um Mecanismo de Busca Acadêmica (MBA). Como Buchinger, Cavalcanti, e Hounsell (2014) demonstraram em seu estudo, sete MBAs se destacaram em um total de 40: Web of Science/Knowledge, Engineering Village, Scopus, IEEEExplore Digital Library, ACM Digital Library, Science Direct e Springer Link.

⁵ <https://www.libreoffice.org/discover/libreoffice/>

Para nosso MSL, foram selecionados os cinco primeiros MBA: Web of Science/Knowledge, Engineering Village, Scopus, IEEEExplore Digital Library e ACM Digital Library. Essa escolha foi feita pois essas bases de busca também aparecem como recomendações em trabalhos como os de Dermeval, Coelho, e Bittencourt (2019). Ou seja, são MBAs conhecidos e considerados relevantes para este tipo de metodologia na área de Computação.

4.3.3 CRITÉRIOS DE INCLUSÃO E EXCLUSÃO

Após a execução das buscas nos MBAs, podem aparecer muitos artigos relevantes e não relevantes para a questão pesquisada. Por isso, para o bom resultado de um MSL também é importante que sejam definidos critérios claros e objetivos para selecionar ou excluir os artigos encontrados ao realizar as buscas (Dermeval, Coelho, and Bittencourt 2019).

Nossa pesquisa busca uma visão sobre os atributos apontados para o abandono na EAD. Porém, devido a grandes diferenças que possam existir entre crianças e adultos, e que fogem do escopo deste trabalho, buscamos artigos que tratem do problema de evasão na EAD apenas com adultos. Além disso, também é importante lembrar que alguns termos estão na lógica de busca para trabalhos que possam ter utilizado esses termos de forma equivocada. Por isso, trabalhos que discutam, por exemplo, o e-Learning apenas como uma ferramenta de auxílio no ensino presencial, serão descartados.

Assim, serão critérios de inclusão (CI):

- CI1: estudos que apresentem causas para o abandono na EAD, seja através de entrevistas, testes ou propostas teóricas e apontem relações entre essas causas e possíveis atributos;
- CI2: estudos que buscam propor soluções que necessitam descrever possíveis atributos/características, como predições de risco de evasão com Aprendizado de Máquina, Mineração de Dados ou Análise de Aprendizagem;
- CI3: estudos enquadrados nos CI1 ou CI2 e que tratem deste tema com estudantes adultos.

E critérios de exclusão (CE):

- CE1: estudos que não possuam relevância com o tema de evasão na EAD, porém caíram na lógica de busca;
- CE2: estudos explicitamente relacionados com crianças, adolescentes e idosos;
- CE3: estudos que aplicam pequenas adições online em cursos presenciais;

- CE4: estudos que não possuam acesso público ou aberto às credenciais da Universidade Federal Fluminense;
- CE5: estudos que apliquem o EAD como testes, comparando com o ensino presencial e não apresentam relações causais entre atributos e a evasão na EAD;
- CE6: estudos duplicados que já foram selecionados durante a análise de outras bases;
- CE7: estudos escritos em uma língua diferente da língua inglesa, porém que tenham caído na lógica de busca devido ao título e resumo estarem escritos em inglês;
- CE8: outros estudos de MSL ou Revisões Sistemáticas similares. Estes representam estudos secundários e não primários, e serão discutidos como trabalhos relacionados;
- CE9: estudos que discutam causas de evasão na EAD apontando como, por exemplo, falta de motivação, porém que não se aprofundem em quais atributos ou características possam representar essa falta de motivação.

4.3.4 EXTRAÇÃO DOS DADOS DO MSL

Nós analisamos os trabalhos para extrair o contexto do estudo e quais atributos foram considerados para predições de evasão na EAD. Nos casos onde não envolveram predições, analisamos quais atributos tiveram relações com a evasão. Após análise, esses atributos ficaram extremamente dispersos.

Em alguns casos, diferentes atributos representavam uma mesma categoria de interação, como por exemplo, atributos "pulou vídeo", "assistiu vídeo até o final" e "assistiu o vídeo duas vezes". Esses três atributos representam uma mesma categoria que pode ser definida como atributo "vídeo". Dessa forma, todos os atributos que ficaram dispersos e puderam ser categorizados em uma única categoria, foram feitos. Porém, também extraímos alguns metadados desses trabalhos para contextualizar e permitir outros ângulos de visualização dos resultados. Os metadados escolhidos foram: ano de publicação, finalidade do trabalho, modalidade de EAD no qual o estudo foi conduzido e país onde o estudo foi conduzido.

Ano de publicação: O ano de publicação de cada trabalho é um metadado extremamente simples para ser extraído e auto explicativo.

Finalidade do trabalho: Foi necessário criar cada categoria de finalidade a medida que os trabalhos foram analisados. Assim, ao final de toda a análise, três finalidades categorizaram todos os artigos: Entendimento, Predição e Modelagem. A primeira finalidade se refere aos artigos que possuem o objetivo de entender que fatores são mais comuns ou levam à evasão. A categoria Predição se refere aos trabalhos que tem como objetivo prever alunos que podem evadir de cursos EAD. A última categoria, Modelagem, se refere aos trabalhos com o objetivo

de modelar o comportamento de alunos, separando em perfis ou grupos de alunos que evadem e aqueles que não evadem.

Modalidade de EAD: Como o EAD possui diversas nomenclaturas com significados e objetivos diferentes. Para este estudo, envolvemos três dessas modalidades: os cursos totalmente online abertos a todos (MOOCs), os cursos totalmente online que não são ofertados como MOOCs e o Ensino Híbrido.

Os trabalhos que realizaram estudos com dados de MOOCs ou em contextos de MOOCs foram classificados desta forma. Por outro lado, trabalhos que apresentaram dados ou estudos realizados em cursos totalmente online, porém não necessariamente aberto a todos, foram categorizados como "Distância". Por fim, os cursos que aplicavam um ensino à distância com provas ou mediações presenciais foram categorizados como híbridos.

Em alguns trabalhos não foram encontradas descrições da origem dos dados ou do contexto e, por isso, foram categorizados como "Não encontrado". Entretanto, também existiram trabalhos que aplicaram mais de uma modalidade para compará-las.

País: Extraímos o país onde os trabalhos foram executados.

4.3.5 FILTRAGEM DOS ESTUDOS

Após o passo 3, fizemos a busca nas bases indexadas Web of Science/Knowledge; Scopus; ACM; Engineering Village e IEEE, durante o segundo semestre de 2019. Os resultados obtidos nessa busca são apresentados a seguir.

Tabela 1: Resultado inicial em cada MBA

IDs	Base	Quantidade de artigos
B1	Web of Science/Knowledge	302
B2	Scopus	552
B3	ACM Digital Library	82
B4	IEEEExplore Digital Library	102
B5	Engineering Village	370
Total		1408

A Tabela 1 demonstra os resultados encontrados em cada base, ou seja, os resultados sem nenhuma análise dos artigos. Esses trabalhos foram, então, analisados da seguinte forma: O primeiro passo foi verificar se o título deixava claro algum CI ou CE. Caso negativo, o resumo do trabalho foi analisado para verificar novamente qual(is) critério(s) deveria(m) ser utilizado(s). Se a dúvida persistisse, era lida a conclusão do trabalho. Por fim, caso não tenha sido identificado nenhum CI depois dessas leituras, o trabalho era então considerado fora do

MSL. Ao final de toda a seleção e corte nos trabalhos duplicados, a quantidade de trabalhos selecionados para o MSL ficou como mostra a Tabela 2.

Tabela 2: Resultado filtrado em cada MBA

IDs	Base	Quantidade de artigos
B1	Web of Science/Knowledge	50
B2	Scopus	24
B3	ACM Digital Library	12
B4	IEEEExplore Digital Library	5
B5	Engineering Village	4
Total		95

Se compararmos a Tabela 1 com a Tabela 2, veremos algumas bases como, B5, que possui um grande número de resultados encontrados, porém apenas 4 selecionados. Isso ocorreu, pois, a seleção dos estudos foi feita na ordem como as bases de dispõe nas tabelas. Ou seja, primeiro verificamos os trabalhos de B1, seguido por B2 e assim até chegar em B5. Porém, ao terminar uma base, a base posterior tinha seus artigos replicados retirados. Assim, ao terminar B1, todos os artigos encontrados em B1 foram retirados de B2 e assim suscetivelmente.

4.3.6 ATRIBUTOS EXTRAÍDOS

Todos os artigos selecionados foram lidos com o objetivo de extrair os atributos que estes trabalhos consideram como impactantes para influenciar na evasão de alunos na EAD. O resultado final dos atributos extraídos é apresentado a seguir.

Tabela 3: Quantidade de trabalhos em relação aos atributos utilizados

Categoria	Atributo	Quantidade
AVA	Notas	49
AVA	Fórum	40
AVA	Sessões	38
AVA	Vídeo	36
AVA	Páginas	33
Demográfico	Idade	31
Demográfico	Gênero	28
Demográfico	Trabalho	19
Demográfico	Localização	18
AVA	Cliques	15
Demográfico	Escolaridade	15
Demográfico	Relacionamento	10
Demográfico	Conhecimento básico de computadores	8
Demográfico	Experiência com EAD	7
AVA	Histórico de notas em outros cursos	7
Demográfico	Filhos	6
Demográfico	Objetivo	3
Demográfico	Família	3
Demográfico	Raça	1

Demográfico	Outros atributos demográficos	1
-------------	-------------------------------	---

A coluna Categoria, da Tabela 3, representa se o atributo está relacionado com uma informação demográfica do aluno como, gênero e idade, ou se está relacionado ao AVA do aluno, ou seja, um comportamento adquirido durante o uso nas plataformas existentes nos cursos EAD. A segunda coluna apresenta o nome do atributo. Por último, a terceira coluna apresenta a quantidade de artigos onde o atributo foi utilizado ou demonstrado como um candidato fortemente relacionado a evasão na EAD. Ressaltando que o somatório dessa coluna não irá refletir a quantidade de artigos estudados, pois é comum a utilização de mais de um atributo em cada trabalho.

Ao analisarmos o resultado geral indicado na Tabela 3, nota-se que foram utilizados mais atributos demográficos. Entretanto, ao olharmos apenas os 5 atributos mais utilizados, podemos observar que são todos atributos relacionados ao comportamento do aluno durante seu uso na plataforma. Esses cinco atributos mais utilizados representam, respectivamente: (1) as notas que os alunos obtêm durante o curso EAD; (2) os comentários, respostas e ações relacionadas aos fóruns presentes nas plataformas; (3) logs de sessões dos alunos, seja tempo total de acesso ou quantidade de acessos em um determinado período; (4) as interações dos alunos com as vídeo aulas dos cursos e (5) histórico de páginas acessadas durante as sessões.

4.3.7 COMPORTAMENTO DOS ATRIBUTOS AO LONGO DO TEMPO




Figura 8: Distribuição top 10 atributos ao longo dos anos (2002-2018)

Ao analisar a Figura 8, que apresenta a distribuição dos 10 atributos mais usadas ao longo dos anos, vemos que o padrão se mantém bem similar. Porém, se considerássemos apenas

até o ano de 2016, os atributos relacionados a vídeos e páginas estariam posicionados antes de localização. Isso indica um grande aumento, em apenas dois anos, na utilização dos logs de interação com vídeos e páginas.

4.3.8 COMPORTAMENTO DOS ATRIBUTOS EM RELAÇÃO À FINALIDADE DOS TRABALHOS

Essa finalidade, como discutido na seção 3.4, foi separada em três categorias: Entendimento, Predição e Modelagem. Porém, antes de analisar os atributos por finalidade, é importante descobrir se o MSL possui uma boa distribuição de trabalhos com finalidades diferentes.




Figura 9: Percentual de trabalhos em cada categoria de finalidade

A Figura 9, que apresenta a porcentagem de trabalhos em cada categoria, demonstra que existe uma distribuição onde nenhuma modalidade está presente na grande maioria dos trabalhos. Mesmo que a maior parte (52.6%) desses artigos tenha como finalidade a predição de alunos em risco de evasão, cerca de 34% dos artigos mapeados possuem a finalidade de entender que atributos poderiam levar alunos a evadir dos cursos e, 12.6% dos trabalhos, a finalidade de modelar alunos que poderiam evadir cursos através de atributos.




Figura 10: Atributos distribuídos por finalidade

Na Figura 10, nota-se que os atributos mudam de prioridade se mudarmos a finalidade. Quando o objetivo é predição, os atributos se mantêm bem semelhantes ao rank geral apresentado na Tabela 3. Entretanto, quando o objetivo foi entendimento, os atributos de sessões e páginas foram pouco utilizados. Por fim, quando a finalidade é modelar os alunos que podem evadir os cursos, os atributos sessões, notas, vídeos, páginas e clicks se tornam os mais populares, respectivamente.

4.3.9 CONTEXTO DOS DADOS

O contexto dos trabalhos diz respeito ao modelo EAD adotado. Esses modelos foram resumidos em três: MOOCs, Distância e Híbrido. O primeiro modelo diz respeito a cursos que são ofertados de forma aberta e totalmente online. O segundo modelo diz respeito a cursos de Ensino Superior que são ofertados totalmente online, porém com restrições para este acesso. Já o terceiro modelo diz respeito aos cursos ofertados de forma híbrida. Ou seja, cursos que possuam, por exemplo, aulas à distância e tarefas presenciais.




Figura 11: Porcentagem por modelo de EAD

Como a Figura 11 demonstra, esse MSL só consegue explorar os resultados sobre os modelos de MOOC e Distância, pois a quantidade de artigos sobre o ensino Híbrido representa menos de 5% entre todos os trabalhos. Por isso, não serão discutidos resultados relacionados ao ensino híbrido.

Observando a Figura 12, nota-se uma diferença dos atributos mais utilizadas entre os cursos ofertados como MOOCs e os cursos da modalidade Distância. Nos MOOCs predominam os atributos obtidos através da interação de plataformas. Até mesmo o atributo "clicks" possui mais uso do que os outros atributos demográficos dos alunos. Em contra partida, os cursos não MOOCs possuem um claro uso maior dos atributos demográficos dos alunos, com exceção das notas.




Figura 12: Atributos por modelo de EAD

Outro fator importante para a análise do contexto é o país onde os dados são aplicados. Se observarmos a Figura 13, notamos que os países com o maior número de autores foram China, Estados Unidos, Espanha, Grécia e Reino Unido. É interessante destacar que, apesar dos países Estados Unidos e Reino Unido terem a língua oficial inglesa, a China se apresentou com o maior número de pesquisadores. E a Espanha demonstrou quase a mesma quantidade de autores do Estados Unidos.




Figura 13: Quantidade de autores por país

4.3.10 LIMITAÇÕES DO MSL

Assim como a própria pesquisa como um todo, o MSL também possui suas limitações. É importante definir as limitações que encontramos para que outros pesquisadores possam

entender melhor o contexto em que fizemos o estudo e até onde esse estudo deve ser considerado.

Como primeiro ponto a ser levantando, devemos destacar que todo o MSL foi conduzido apenas por uma pessoa, ao contrário da recomendação de Dermeval, Coelho, e Bittencourt (2019). Porém todo o processo foi feito rigorosamente ao longo de quatro meses. Outra limitação importante a ser reforçada nesta seção é um fato que já apresentamos anteriormente: todos os artigos que analisamos foram trabalhos com acesso gratuito através de nossa Universidade.

4.4 ENTREVISTAS PARA IDENTIFICAR CARACTERÍSTICAS RELACIONADAS AO ABANDONO NA EAD

Como discutido anteriormente, uma explicação está intrinsecamente ligada ao contexto em que ela é aplicada. Logo, nós não podemos inferir que as informações relativas a primeira pergunta de pesquisa, que foram extraídas do mapeamento sistemático discutido na seção anterior, irá refletir totalmente no contexto em que desejamos colocar em teste: o EAD no Brasil. Por isso, para definir o peso das informações extraídas do mapeamento sistemático, também realizamos entrevistas com educadores e alunos que participam de um modelo de EAD.

As entrevistas de pesquisa são uma forma eficiente para coleta de dados, explorando as experiências, visões e motivações de pessoas em um determinado assunto (DiCicco-Bloom and Crabtree 2006; Gill et al. 2008). Através de entrevistas aplicadas corretamente é possível obter um entendimento mais profundo sobre um assunto do que o conhecimento obtido por meio de questionários, por exemplo (May 2013; Silverman 2017).

Segundo Creswell (2003, 2007), para que uma entrevista possa ter um resultado efetivo é preciso ter uma boa preparação para a entrevista e construir perguntas efetivas. Por isso, no modelo para o planejamento de entrevista utilizado nessa pesquisa, primeiro, (1) nós definimos o objetivo da entrevista. Após o passo 1, (2) nós definimos o perfil desejado dos entrevistados. Com essas definições prontas, foi possível (3) escolher, efetivamente, o tipo de entrevista que foi adotada. Os próximos passos foram baseados no tipo de entrevista escolhida no terceiro passo, e consistiram de: (4) montar um conjunto de perguntas chave, que poderiam ou não ser feitas, como base para a entrevista, e, por último, (5) foi realizada uma entrevista piloto para testes e ajustes que poderiam alterar qualquer um dos passos anteriores.

4.4.1 DEFINIÇÃO DO OBJETIVO E PERFIL DESEJADO PARA AS ENTREVISTAS

Como foi descrito no início desta seção, o objetivo dessa entrevista é adquirir conhecimento sobre os motivos que podem levar alunos a abandonar seus cursos em um modelo de EAD. Com isso, nós iremos confrontar com as informações extraídas do mapeamento sistemático e obter um conhecimento mais sólido sobre as causas que levam ao abandono de alunos na EAD.

A partir desse objetivo, nós buscamos entrevistar três tipos de perfis: professores de cursos que estejam envolvidos no modelo de EAD a, pelo menos, 1 ano; alunos que tenham cursado, pelo menos, dois semestres de disciplinas em um modelo de EAD; alunos que abandonaram cursos no modelo de EAD. Nós colocamos restrições mínimas de experiência nos perfis 1 e 2 para que a seleção dos entrevistados para a pesquisa possa garantir indivíduos qualificados para tratar do assunto.

Além disso, para atingir esses perfis desejados, nós optamos por um programa de governo implantado no Brasil, no estado do Rio de Janeiro, chamado Centro de Educação à Distância do Estado do Rio de Janeiro (CEDERJ). O Cederj é uma parceria entre o governo do estado do Rio de Janeiro e as universidades Centro Federal de Educação Tecnológica Celso Suckow da Fonseca (CEFET-RJ), Universidade Federal do Rio de Janeiro (UFRJ), Universidade do Estado do Rio de Janeiro (UERJ), Universidade Estadual do Norte Fluminense Darcy Ribeiro (UENF), Universidade Federal Fluminense (UFF), Universidade Federal do Estado do Rio de Janeiro (UNIRIO) e Universidade Federal Rural do Rio de Janeiro (UFRRJ) (Bielschowsky 2017).

O modelo de ensino adotado pelo Cederj conta com vídeo aulas e textos disponíveis em um ambiente virtual de aprendizagem (AVA) e professores presenciais em polos, espalhados pelo Rio de Janeiro. Então, os alunos devem ir para realização de provas avaliativas, mas também podem ir para tirar suas dúvidas com os professores presentes (Bielschowsky 2017).

Como o principal objetivo do Cederj é funcionar como uma ponte entre universidades e pessoas que almejam cursar o ensino superior à distância, surge como um local que organiza professores e alunos de 7 universidades e 15 cursos diferentes, do ensino superior (Bielschowsky 2017). Assim, nós esperamos obter um grupo de entrevistados com mais representatividade, porém ainda homogêneo, o que é um fator importante (DiCicco-Bloom and Crabtree 2006).

4.4.2 TIPO DE ENTREVISTA ESCOLHIDA

Tanto Gill e colegas (2008), quanto DiCicco-Bloom and Crabtree (2006) destacam que as entrevistas qualitativas podem ser categorizadas em três tipos principais de entrevistas de pesquisa: estruturada, semiestruturada e não estruturada. As entrevistas estruturadas são realizadas com perguntas predefinidas, em que o entrevistador não aplica nenhuma, ou quase nenhuma, alteração no momento da entrevista (DiCicco-Bloom and Crabtree 2006; Gill et al. 2008). Por esse motivo, as entrevistas estruturadas costumam ser rápidas e de fácil administração (Gill et al. 2008; Silverman 2017).

Já as entrevistas semiestruturadas possuem perguntas que endereçam o assunto principal (DiCicco-Bloom and Crabtree 2006; Gill et al. 2008). Entretanto, tanto o entrevistador quanto o entrevistado, podem discutir abertamente sobre o assunto, mesmo que não seja resposta para uma das perguntas (Gill et al. 2008; Silverman 2017). Por último, as entrevistas não estruturadas possuem nenhuma, ou quase nenhuma, pergunta (DiCicco-Bloom and Crabtree 2006; May 2013). São entrevistas que, a partir de um início provocado pelo entrevistador, devem se desenrolar de forma natural (Gill et al. 2008).

Nós descartamos as entrevistas estruturadas e não estruturadas, pois enquanto a primeira, apesar de ser rápida e de fácil organização, não permite uma coleta de dados profunda, a segunda pode não se desenrolar naturalmente, tornando-se mais difícil para execução (DiCicco-Bloom and Crabtree 2006; Gill et al. 2008). Portanto, o tipo de entrevista escolhida para esta pesquisa foi a entrevista semiestruturada.

Além do tipo de entrevista, ainda deve-se decidir se as entrevistas serão conduzidas individualmente com cada entrevistado ou em grupos. A primeira forma de conduzir permite que o entrevistador construa um “relacionamento” individual com o entrevistado, o que pode gerar um compartilhamento de detalhes mais profundos por parte de cada indivíduo entrevistado. Já a segunda, por ser conduzida como um grupo com vários entrevistados, gera um conhecimento sobre a visão coletiva de um determinado assunto (DiCicco-Bloom and Crabtree 2006; Gill et al. 2008).

Como nosso objetivo com as entrevistas é buscar entender o que pode levar um aluno a abandonar cursos na modalidade do EAD, na visão de alunos e professores, nós optamos por conduzir as entrevistas individualmente. Pois, os professores podem ter críticas ao modelo de ensino, críticas a um tipo de comportamento de algum outro educador, ou mesmo críticas ao ambiente, o que poderia não ser exposto em uma entrevista conduzida em grupo. O mesmo vale para os alunos.

4.4.3 PERGUNTAS PARA AS ENTREVISTAS

As entrevistas semiestruturadas contam com perguntas que devem instigar os entrevistados para que uma informações de qualidade possam ser extraídas nas análises finais (Gill et al. 2008; May 2013). Isso implica duas coisas: (1) para que os entrevistados possam compartilhar suas experiências da melhor forma possível, é preciso que eles se sintam confortáveis na entrevista (Creswell 2007; DiCicco-Bloom and Crabtree 2006) e (2) as perguntas não devem influenciar, de nenhuma forma, a resposta dos entrevistados (McNamara 2009).

Fatores como esses descritos no parágrafo anterior tornam clara o papel crucial que as perguntas desempenham para uma entrevista de sucesso. Por isso, para desenvolver as perguntas utilizadas em nossa entrevista, nós seguimos as recomendações de McNamara (2009) e DiCicco-Bloom and Crabtree (2006): as perguntas devem ser abertas o suficiente para que os entrevistados possam escolher os próprios termos nas respostas; evitar evocativo e julgamento, para as perguntas não influenciarem na resposta; realizar uma pergunta por vez; criar perguntas claras, com termos específicos da cultura dos entrevistados; iniciar com perguntas que criem conforto e relação com o entrevistado.

Ao unir essas recomendações com minha experiência de 4 anos como aluno de um curso de EAD e 2 anos como educador na EAD, desenvolvemos as perguntas que podem ser encontradas nos Apêndices A e B, ao final deste trabalho. Além disso, também realizamos uma entrevista piloto para verificar e corrigir possíveis falhas na forma como conduzimos e nas perguntas que adotamos.

Dessa forma, as cinco primeiras perguntas possuem o papel de criar conforto e aproximação com o entrevistado. Já as próximas perguntas possuem o papel de iniciar a reflexão do educador sobre problemas que ele ou algum aluno tenha vivenciado. Por último, temos três últimas perguntas para atacar o problema de evasão na EAD. Em especial, as perguntas 8 e 9, apesar de serem similares, podem ajudar a extrair mais informações, pois na pergunta 8, perguntamos o que o educador vê como problemas que podem levar ao abandono, enquanto na pergunta 9, perguntamos por soluções. Isso é para evitar que um ponto importante passe despercebido por se tratar apenas de uma visão como problema, ou de uma visão como solução.

Apesar de diferentes, as perguntas desenvolvidas para os alunos possuem o mesmo pensamento e objetivo que as perguntas feitas para os educadores. Vale destacar que as perguntas para os educadores e alunos podem ser visualizadas nos Apêndices ao final deste trabalho.

4.4.4 CONDUÇÃO DAS ENTREVISTAS

A forma como uma entrevista deve ser conduzida é tão importante quanto os outros fatores que compõe a entrevista (W Turner 2010). Por isso, para que possamos obter entrevistas efetivas, nós adotamos alguns conselhos de McNamara (2009) e Creswell (2007), como: evitar demonstrar surpresa ou alegria em respostas que possam influenciar respostas para outras perguntas; se manter o mais neutro possível; não perder o controle da entrevista quando entrevistados demorarem muito para responder uma pergunta ou mesmo fugir do tópico da pergunta; informar mudanças de tópicos e verificar regularmente a gravação.

Assim, com as recomendações em mente, nossa entrevista será conduzida da seguinte forma: O primeiro passo é (1) a escolha de uma local com pouca distração, seguido da (2) explicação da proposta da entrevista. Após isso, nós iremos (3) apresentar e descrever os termos de consentimento, (4) explicar o formato da entrevista, (5) quanto tempo espera-se que a entrevista irá demorar e (6) indicar como entrar em contato conosco, após a entrevista. Os dois últimos passos, antes da entrevista começar, consistem de (7) abrir espaço para que o entrevistado faça alguma pergunta, caso tenha dúvida, e (8) iniciar a gravação, em áudio, da entrevista.

Após início, (9) as perguntas serão iniciadas. Porém é importante observar que a entrevista semiestruturada permite que uma pergunta possa ser alterada ou adicionada, caso o entrevistador ache necessário. Além disso, podem ocorrer situações em que a ordem das perguntas mude para que permaneça um fluxo de conhecimento sobre um determinado assunto (Creswell 2007; W Turner 2010). Por exemplo, caso o entrevistado entre no problema de abandono na primeira pergunta sobre a opinião dele em relação ao EAD, convém ir para as perguntas principais e, depois, voltar para as iniciais. Ao final, quando as perguntas terminarem, o entrevistado (10) será lembrado do termo de consentimento e da forma para entrar em contato, caso queira.

Em relação a escolha do local para as entrevistas, elas serão conduzidas, prioritariamente, nos polos onde os professores trabalham e onde os alunos estão acostumados. O motivo dessa escolha é para que os entrevistados estejam em um ambiente conhecido e sintam-se mais confortáveis, algo importante para as entrevistas (DiCicco-Bloom and Crabtree 2006; W Turner 2010). Caso alguma entrevista não seja possível no local escolhido, a entrevista será conduzida por meio de vídeo chamada ou outra forma que o entrevistado possa preferir.

4.4.5 ANÁLISE DAS ENTREVISTAS

Existem diferentes métodos para fazer a análise das entrevistas (Creswell 2007; Wertz et al. 2001). Wertz e colegas (2001), por exemplo, citam cinco formas diferentes: psicologia fenomenológica, teoria fundamentada, análise de discurso, pesquisa narrativa e inquérito intuitivo. Creswell (2007) é outro autor que também discute sobre os métodos narrativo, fenomenológico e teoria fundamentada. Em especial, outros trabalhos também discutem sobre estes métodos (Burck 2005; Caregnato and Mutti 2006).

Baseado no estudo destes trabalhos, optamos pela análise de discurso. Optamos por este tipo de análise, pois é um método focado na identificação do sentido existente dentro de um conteúdo textual e oral (Caregnato and Mutti 2006; Creswell 2007). Seguindo este método, fomos capazes de extrair os atributos que os educadores do EAD consideram impactantes para a evasão de alunos, sem que eles tenham, necessariamente, dito o atributo de forma explícita (embora, em alguns casos, nota-se essa fala explícita).

Assim sendo, de acordo com as recomendações de Creswell (2007), realizamos a transcrição de todas as entrevistas e fizemos uma análise sobre as falas dos educadores. Durante o processo de transcrição, seguimos continuamos com as recomendações de Creswell (2007) e o máximo de alteração que fizemos sobre as falas está na formalização das palavras. Por exemplo, falas "pra" foram trocadas por "para".

Então, após a transcrição de todas as entrevistas, fizemos a análise discursiva sobre as falas, procurando extrair os atributos que os educadores consideravam como impactantes para o abandono na EAD. Essa análise foi feita de forma intra sujeitos e inter sujeitos. Na seção abaixo, 4.4.6, destacamos as falas que geraram nossas interpretações sobre o resultado das entrevistas.

4.4.6 RESULTADO DAS ENTREVISTAS

Foram realizadas 4 entrevistas com educadores e nenhuma entrevista com alunos, por falta de voluntários. Esses educadores representavam os cursos Segurança Pública (UFF), Sistemas de Computação (UFF), Pedagogia (UERJ) e Administração (UFRRJ).

Após a análise discutida na seção anterior, separamos exemplos de falas onde os atributos utilizados para inferir evasão aparecem. Ou seja, os atributos que os educadores do EAD consideram importantes para identificar alunos em risco de evasão na EAD.

P1: *“as notas e, principalmente, a frequência presencial e nas plataformas”*

P1: *“Outra coisa que eu faço é olhar todo final de semestre. (...) eu vejo o aluno que iniciou o curso e não fez alguma prova no final do período. (...) Isso eu faço desde 2016 e tem dado bastante resultado.”*

P3: *“A partir do momento que começam a não estudar, a não tomar o devido gosto dela pelo curso, ela começa a perder cronograma, começa a perder datas importantes e aí vira uma bola de neve”*

P2: *“(...) parece muito claro e que acontece bastante: o aluno presta o vestibular para o curso EAD, entra e não tem a menor afinidade e conhecimento em informática básica.”*

P2: *“(...) a distância do aluno para o polo. Acho extremamente importante aqui. Sei que é complicado, mas renda também.”*

P2: *“O tempo que está fora de estudos. Por exemplo, pessoas mais velhas que formaram no ensino médio a 16, 17 anos, tendem a desistir.”*

P2: *“Quantas vezes o aluno veio as tutorias, informações de avaliações, né? Quantas AD ele entregou, em quantas AP ele foi. Porque isso já vai indicando a desistência. Se logo no início, primeira AD ele não entrega e primeira AP ele não faz, pelo que eu tenho visto, aquele ali provavelmente vai abandonar.”*

P3: *“(...) Está a cento e tantos quilômetros daqui. Eu já marco aquele aluno como propenso a não continuar. (...) Não é um índice infalível. Mas já é algo que merece um peso, porque ele não está muito perto do polo. Então, pode ser que ele não vá vir aqui buscar ajuda e tal.”*

P3: *“Então, vendo a maioria dos alunos que começaram a vir nas primeiras semanas de tutoria, continuam vindo depois.”*

P3: *“Eu acho que, a partir daí, seria um acompanhamento da grade.”*

P3: *“A partir do momento em que as vídeo aulas são online, não existe o ‘a qualquer hora e a qualquer momento’. É a qualquer hora e a qualquer momento que você tenha um recurso computacional e uma conectividade de qualidade disponível para você consumir aquele recurso.”*

P4: *“(...) as pessoas que trabalham em outros lugares. Eu vejo essa dificuldade neles, ainda mais pessoas que trabalham em comércio.”*

P4: *“(...) começam a perder Atividades à Distância, não entram muito na plataforma. Começam a perder prazos, começam a faltar Avaliações Presenciais (...)”*

P4: *“onde ele mora, qual a disponibilidade que ele tem para ir ao polo, se ele pretende formar grupos de estudos com outros alunos ou se já tem algum grupo de estudo, frequência*

com que vem ao polo, com que frequência ele usa a plataforma, se ele lê todas as informações lá (...).”

Nestes comentários, podemos ressaltar os atributos nota, acesso à plataforma, conhecimento prévio em informática, localização do aluno, idade, acesso à computador e internet e disponibilidade para estudo (se o aluno trabalha, quanto tempo trabalho, etc). Porém, também tivemos citações de atributos que são requisitados por sistemas que estes educadores utilizam.

P1: *“(...) temos também o acompanhamento que a gente faz na plataforma. É, basicamente, colocar data de nascimento do aluno e se ele veio nas primeiras tutorias.”*

P2: *“(...) que a gente faça um acompanhamento dos alunos (...) (e nós perguntamos) (...) em que ano o aluno terminou o ensino médio.”*

P2: *“Ele (acompanhamento) é feito com os calouros, que é onde eu noto a maior evasão: primeiro, segundo e terceiro período. Depois que a galera engrena, só vai trancar se tiver um problema de saúde ou coisa do tipo.”*

Esses sistemas também receberam críticas e sugestões. Entre elas, destacamos a necessidade que já existe dos educadores não terem como visualizar informações que gostariam e a falta de confiança nestes sistemas.

P3: *“(...) você consegue visualizar a última vez que ele esteve na sala da disciplina. Não tem nada de que ‘o aluno acessou, assistiu 3 vezes e depois fechou o acesso’, eu só sei que ele acessou. Ele pode ter acessado simplesmente para olhar a cara da plataforma e fechou, mas já vai estar constando ali que ele acessou.”*

P3: *“Ela não me dá, digamos, nada confiável se o aluno está avançando ou não. O próximo acompanhamento que pode ser feito seria a visualização das avaliações.”*

P3: *“(...) acho que seria bacana, de repente, a gente ter o acesso a uma ferramenta que você pudesse acompanhar a evolução do aluno dentro do curso.”*

E, por fim, também tivemos citações de causas envolvendo o abandono que não se enquadram como atributos. Por exemplo, organização pessoal do aluno e expectativas erradas sobre os cursos.

P2: *“O aluno, no início, ele define muito isso: a quantidade de horas (que vai estudar por dia). Mas, eu acho que a grande maioria não consegue cumprir isso.”*

P2: *“O aluno tem a impressão que o EAD vai ser mais fácil do que o ensino presencial”*

P3: *“Não conseguem organizar tempo para estudar e não conseguem desenvolver autonomia de estudo”*

P4: “(...) alguns alunos pensam que o fator de ser um curso à distância, não precisa ter contato com o polo. E quando você perde esse contato com outros alunos, com o tutor, quem quer que seja, né, com pessoas. Eu acho que isso pesa na hora do aluno ir adiante.”

P4: “Outro problema, são as pessoas que escolhem Pedagogia por ser, entre aspas, ‘mais fácil’. E Pedagogia é pra quem realmente quer enveredar pela educação.”

4.5 MSL X ENTREVISTAS

Nesta etapa comparamos os resultados obtidos através do MSL com os resultados obtidos através das Entrevistas. O objetivo principal era descobrir se os fatores relacionados ao abandono que são considerados importantes pelos professores e alunos, representam os atributos utilizados no desenvolvimento e treinamento dos modelos preditivos.

Então, analisando os comentários dos educadores com os resultados do MSL, é fácil notar que eles coincidiram. Portanto, para o treinamento de nosso modelo, utilizamos os atributos notas, acesso à plataforma, acesso ao fórum e discussões, idade, renda familiar, condição de trabalho e se possui computador em casa.

No próximo capítulo descrevemos todo o desenvolvimento da ferramenta para a simulação. Após essa descrição, o capítulo 6 contém os detalhes sobre as avaliações realizadas pelos educadores do EAD, ao utilizar a ferramenta.

CAPÍTULO 5 – DROP ICT

Neste Capítulo discutimos como a ferramenta desenvolvida nesta pesquisa para mediar a interação de professores com modelos preditivos foi construída. Apresentaremos sua estrutura, a definição da interface segundo a ES e a criação dos modelos preditivos.

5.1 FUNCIONAMENTO DA FERRAMENTA

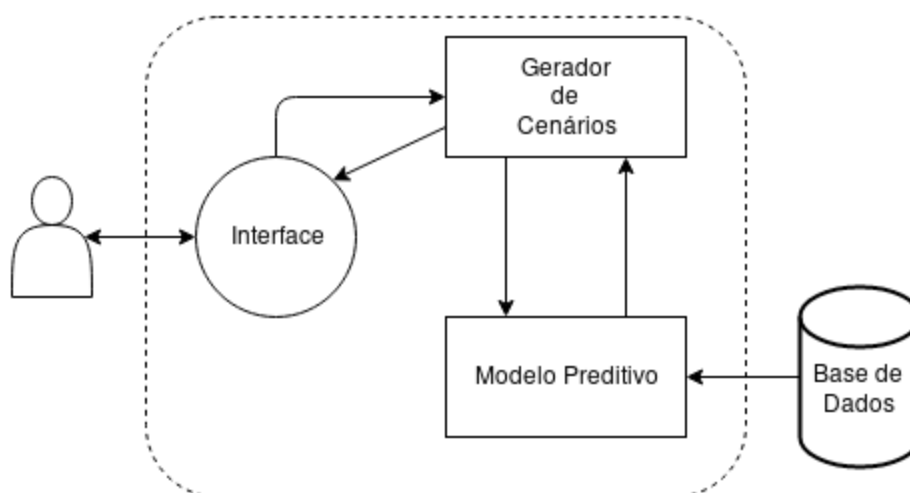


Figura 14: Funcionamento da ferramenta

Como mostra a Figura 14, a ferramenta é constituída por 2 componentes (retângulos) e a interface que permite esta interação. Em síntese, o componente Modelo Preditivo recebe os dados reais de um AVA e realiza suas predições. Essas predições reais são apresentadas pelo usuário através da interface. Para efeitos comparativos, o usuário também pode simular casos, através do Gerador de Cenários, alterando uma cópia dos dados de um aluno. Ao observar estes cenários, compara-los e encontrar suas diferenças, o educador poderá investigar o resultado do modelo preditivo e chegar a conclusões sobre seu funcionamento.

5.2 ESTRUTURA DA FERRAMENTA

Para alcançar este objetivo construímos a ferramenta em duas etapas: o desenvolvimento de uma *Application Programming Interface* (API) contendo os modelos preditivos já treinados e o desenvolvimento da aplicação *web*, que terá o Gerador de Cenários e será o meio de interação para os usuários.

Após criação dos modelos, tínhamos os modelos de dados que os representavam. Porém, para que esses modelos possam ser utilizados efetivamente, em termos de código, eles precisam ser abertos, receber os dados de entrada e retornar seus resultados.

Por isso, foi preciso adotar uma forma que pudesse escolher qual modelo deveria ser aberto para passarmos os dados e recebermos sua predição. Nesse caso, com os três modelos prontos, optamos por deixá-los separados da aplicação web, para que o modelo preditivo não fosse executado no lado do cliente.

Essa decisão, além de melhorar o desempenho e permitir uma maior proteção do modelo, também auxilia a separar as necessidades para teste de toda essa pesquisa, o que consideramos o ponto mais importante. Por exemplo, ao separarmos o uso dos modelos preditivos em uma API, estamos deixando claro que a aplicação web poderia realizar suas consultas de predições em qualquer modelo fornecido por qualquer outra API.

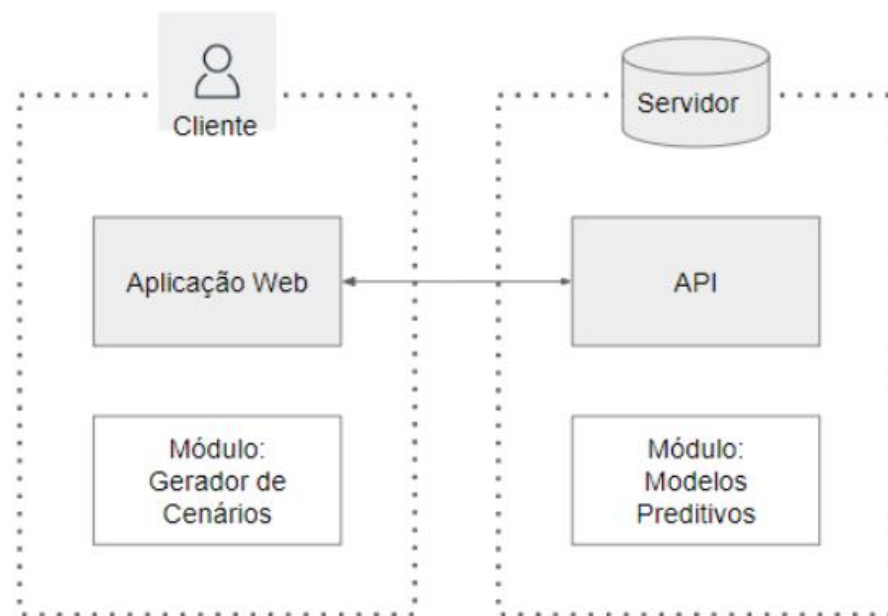


Figura 15: Estrutura da ferramenta Dropict

Dessa forma, a dependência de funcionalidades principais de todo o ambiente de teste pode ser definida como mostra a Figura 15. Ou seja, temos a aplicação web onde o usuário utilizará para interagir e observar os resultados, e também temos a API, executada em outro servidor, onde os modelos de fato estão armazenados e são utilizados. Ao consultar a API, a aplicação web envia uma requisição *Representational State Transfer* (REST) contendo uma chave de autenticação para permissão de acesso e um corpo em formato *JavaScript Object Notation* (JSON) com a especificação de qual modelo deve ser consultado e os dados de entrada para a predição do modelo. Como retorno dessa chamada, a API envia o estado de verdadeiro

ou falso, onde verdadeiro significa que o aluno está em risco de evasão, e falso significa o contrário.

5.3 DESENVOLVIMENTO

Como separamos o ambiente de simulações Dropict em dois: aplicação web e API, então também separamos seu desenvolvimento. Nesta seção apresentamos como ocorreu o desenvolvimento de ambas as partes.

5.3.1 APLICAÇÃO WEB

A aplicação web, ou seja, o sistema que o educador irá acessar para interagir com os modelos, simular previsões e comparar os resultados, foi desenvolvida utilizando a linguagem Javascript. Por se tratar de uma ferramenta com uma interface interativa, também foi necessário utilizar a linguagem de marcação HTML e as folhas de estilo *Cascading Style Sheets* (CSS). Por fim, todo o desenvolvimento da interface dinâmica utilizou a biblioteca React⁶.

Como a API é responsável apenas pelo uso dos modelos preditivos, então a aplicação web também é onde os educadores farão suas simulações e comparações. Assim, o Gerador de Cenários foi desenvolvido para funcionar na aplicação web.

Para desenvolver este Gerador de Cenários, utilizamos uma lógica de cópia profunda sobre os dados do aluno selecionado. Então, quando um aluno é selecionado, o código armazena uma cópia de todas as informações deste aluno e exibe esta cópia como forma de alteração para o educador. Dessa forma, qualquer edição que o educador realize para testar suas hipóteses, é feita nesta cópia e seu resultado é armazenado em uma lista atualizada e exibida em tempo de execução para o educador.

5.3.2 API

Esta API foi desenvolvida totalmente em Python⁷ para facilitar a interação com os modelos já treinados. Porém, para criar uma API no padrão REST em Python, foi necessário utilizarmos algumas dependências como Flask⁸, que consiste em uma biblioteca que permite a criação de métodos que esperam chamadas no padrão REST, de acordo com parâmetros pré-definidos.

Com o objetivo de manter uma segurança maior, um destes parâmetros que definimos é uma chave de autenticação criptografada que passou a ser necessária no cabeçalho da chamada

⁶ <https://pt-br.reactjs.org/>

⁷ <https://www.python.org/>

⁸ <https://flask.palletsprojects.com/en/1.1.x/>

REST. Isso evita que qualquer outra aplicação requisitasse nossos modelos preditivos, sem que tenha conhecimento desta chave. Já os outros parâmetros consistem em uma palavra-passe vinda de um dicionário existente na API, que representa todos os possíveis modelos preditivos existentes naquela API, e o corpo JSON dos dados de entrada.

Por isso, ao receber uma chamada para realizar uma predição, a API verifica se a chave de autenticação informada existe e se está correta. Em caso afirmativo, ela prossegue para o parâmetro responsável pelo tipo de modelo que deve ser utilizado. Ao encontrar o modelo requisitado, o código recebe os dados do aluno informado, abre o modelo preditivo e realiza sua predição passando os valores dos atributos na ordem e forma correta. O resultado dessa predição é então retornado como um estado que pode ser verdadeiro, em caso de alunos em risco de evasão, ou falso caso contrário.

5.3.3 MODELOS PREDITIVOS

Como os modelos preditivos representam uma parte essencial para nossa pesquisa, é importante descrevermos como conduzimos todo o seu processo de treinamento até sua conclusão. Por isso, nesta seção discutimos os modelos escolhidos, seus algoritmos, métodos de avaliação de acurácia e a própria base de dados que contém os dados de treinamento.

5.3.3.1 BASE DE DADOS PARA O TREINAMENTO

Para treinar este modelo, utilizamos uma base de dados do Instituto Federal do Mato Grosso (IFMT). Essa base foi construída através do AVA do IFMT e conta com 432 linhas, onde cada linha representa um aluno diferente.

Cada aluno possui um total de 59 atributos diferentes. Ou seja, a base possui 51 colunas: Nome, Arquivo, Chat, Fórum, Glossário, Lição, Módulo de discussão, Pastas, Páginas, Questionário, Sistema, Tarefas, Urls, Total de acessos, Disc1, NOTA-EAD, DISC2, NOTA-ALG, DISC3, NOTA-FDW, DISC4, NOTA-FMI, DISC5, NOTA-MAT, DISC6, NOTA-THM, SIT_PERIODO, Q1, Q2, Q3, Q4, Q5, Q6, Q7, Q8, Q9, Q10, Q11, Q12, Q13, Q14, Q15, Q16, Q17, Q18, Q19, Q20, Q21, Q22, Q23, Sexo, Idade, E_Civil, Raça, trabalha, qtde_resid_casa, Renda_Familiar, PC_casa e EVADIDO.

Os atributos Arquivo, Chat, Fórum, Glossário, Lição, Módulo de discussão, Pastas, Páginas, Questionário, Sistema, Tarefas, Urls e Total de acessos representam quantidades de acessos daquele aluno, naquele módulo do AVA. Já os atributos Disc1, NOTA-EAD, DISC2, NOTA-ALG, DISC3, NOTA-FDW, DISC4, NOTA-FMI, DISC5, NOTA-MAT, DISC6, NOTA-THM, Q1, Q2, Q3, Q4, Q5, Q6, Q7, Q8, Q9, Q10, Q11, Q12, Q13, Q14, Q15, Q16,

Q17, Q18, Q19, Q20, Q21, Q22, Q23 representam notas de um determinado aluno, em questionários e disciplinas. SIT_PERIODO indica se o aluno foi ou não aprovado e EVADIDO indica se o aluno evadiu ou não do curso. Os atributos demográficos, E_Civil, trabalha, qtde_resid_casa e PC_casa, representam o estado civil do aluno, se ele trabalha e de que forma, quantas pessoas residem na casa onde mora e, por fim, se possui ou não computador em casa.

Como discutido anteriormente, em nossa análise do MSL com as Entrevistas, utilizamos os atributos FORUM, MOD_DISCUSSION, TOTAL_ACESSO, NOTA_EAD, NOTA_ALG, NOTA_FDW, NOTA_FMI, NOTA_MAT, Sexo, Idade, E_Civil, Raca, trabalha, qtde_resid_casa, Renda_Familiar, PC_casa e EVASAO. Assim, com FORUM, MOD_DISCUSSION e TOTAL_ACESSO, temos atributos que se relacionam com a quantidade de acessos do aluno; com NOTA_EAD, NOTA_ALG, NOTA_FDW, NOTA_FMI e NOTA_MAT, temos atributos que se relacionam com as notas; Sexo, Idade, E_Civil, Raca, trabalha, qtde_resid_casa, Renda_Familiar e PC_casa, temos atributos sensíveis.

5.3.3.2 DESCRIÇÃO DOS ATRIBUTOS E SUAS DISTRIBUIÇÕES

- FORUM: Este atributo é número inteiro e possui valor mínimo de 0 e máximo de 1138.
- MOD_DISCUSSION: Este atributo é numérico inteiro e possui valor mínimo de 0 e máximo de 16.
- TOTAL_ACESSO: Este atributo é numérico inteiro e possui valor mínimo de 0 e máximo de 5894.
- NOTA_EAD, NOTA_ALG, NOTA_FDW, NOTA_FMI e NOTA_MAT: Estes atributos são numéricos com casas decimais e valor mínimo de 0 e máximo de 10,0.
- Sexo: Este atributo é descritivo e possui os valores masculino (66,9%) e feminino (33,1%).
- Idade: Este atributo era numérico inteiro com valor mínimo de 16. Porém, como mostra a Figura 16, o atributo foi discretizado.




Figura 16: Distribuição do atributo Idade

- Estado Civil: Este atributo é descritivo e possui os valores mora junto (17,6%), viúvo (0,2%), solteiro (42,4%), casado 36,8%), divorciado (2,8%) e separado (0,2%).
- Raça: Este atributo é descritivo e possui os valores mestiça (19,7%), outra (19%), negra (20,4%), branca (40,3%) e indígena (0,7%).
- Trabalha: Este atributo é descritivo e possui os valores parcial (4,9%), não (17,8%), eventual (3%) e integral (74,3%).
- Quantidade de pessoas residem na mesma casa: Este atributo é descritivo e possui os valores 1 (7,6%), 2 (19,9%), 3 (29,2%), 4 (27,3%) e 5 ou mais (16%).
- Renda Familiar: Este atributo era numérico ponto flutuante com valor mínimo de 950,56. Porém, como mostra a Figura 17, o atributo foi discretizado.




Figura 17: Distribuição do atributo Renda_Familiar

- PC em casa: Este atributo é descritivo e possui os valores sim (91,7%) e não (8,3%).
- Evasão: Este atributo é descritivo e possui os valores sim (74,8%) e não (25,2%). É o atributo classe de nosso modelo.

Como descrito, os atributos Idade e Renda_Familiar foram discretizados. O objetivo dessa discretização é representar os dados em formas de categorias para que seus diferentes valores numéricos, que possam ser próximos uns aos outros, não possuam pesos diferentes no processo de aprendizado (Ramírez-Gallego et al. 2016).

Para a discretização, utilizamos o método simples de distribuição por mesmo tamanho (Chmielewski and Grzymala-Busse 1996). Neste método, simplesmente dividimos o conjunto de valores numéricos em partes iguais, ou mais próximas possíveis (Chmielewski and Grzymala-Busse 1996; Kerber 1992; Liu and Setiono 1995).

Além da discretização, todos os atributos numéricos foram normalizados. Esse processo de normalizar os dados numéricos consiste de uma técnica para colocar diferentes atributos numéricos em um mesmo peso (Chmielewski and Grzymala-Busse 1996; Kerber 1992; Liu and Setiono 1995). Assim, por exemplo, os atributos FORUM, que possuem valores entre 0 e 5000, não iriam impactar o uso de atributos como as notas, que possuem valores entre 0 e 10.

O método escolhido para a normalização foi o min-máx (J. Y. Kumar and Kumar 2011; Patro and sahu 2015). Como mostra a Figura 18, para normalizar um valor x_i , basta pegar este valor, subtrair pelo menor valor possível daquele atributo, e dividir o resultado pela subtração do maior valor possível do atributo com o menor valor possível do atributo.

Optamos pelo uso destes métodos de discretização e normalização devido ao nosso objetivo principal. Como não buscamos atingir a melhor acurácia ou testar diferentes métodos de predição, utilizamos os métodos considerados mais simples.

$$z_i = \frac{x_i - \min(x)}{\max(x) - \min(x)}$$

Figura 18: Fórmula para normalização Min Max

5.3.3.3 ALGORITMOS PARA TREINAMENTO

Existem diversos algoritmos para o treinamento de modelos preditivos classificatórios (Akoka, Comyn-Wattiau, and Laoufi 2017; Alpaydın 2010; Han, Kamber, and Pei 2012; Mitchell 1999).

Essa grande variedade de algoritmos pode tornar até mesmo difícil a escolha de qual deve ser utilizado para quais propósitos. Entretanto, como nosso objetivo é verificar se o uso das simulações de cenários permite que os educadores investiguem e questionem os resultados dos modelos, então optamos por realizar o treinamento de três modelos. Dessa forma, os educadores executarão as avaliações em diferentes modelos e, assim, verificaremos se as experiências destes educadores serão diferentes ao trocar o modelo. Os três algoritmos escolhidos foram: k-NN, Árvore de Decisão e Rede Neural. A justificativa para a escolha de cada um destes algoritmos será apresentada em suas respectivas seções, logo abaixo.

Para o treinamento e teste de acurácia de todos os três, utilizamos a técnica recomendada chamada K-fold Cross Validation (Hastie, Tibshirani, and Friedman 2009; Reitermanova 2010). Esta técnica é utilizada para dividir a base de dados em um conjunto para o treinamento e um conjunto para os testes pós treinamento (Han, Kamber, and Pei 2012; Hastie, Tibshirani, and Friedman 2009; Reitermanova 2010).

Esta técnica é importante para que a acurácia apresentada pelos testes finais seja mais precisa. A base de dados é dividida em k partes e, então, em cada uma dessas partes é retirado x% dos dados para os testes. Em geral, a recomendação é utilizar 30% da base de dados como teste e um k com valor 10 (Han, Kamber, and Pei 2012; Hastie, Tibshirani, and Friedman 2009; Reitermanova 2010).

Nós utilizamos esses valores recomendados por Reitermanova (2010). Além disso, após verificação das acurácias, realizamos um novo treinamento dos modelos com todos os dados da base.

Todo o pré-processamento, divisão da base, testes e treinamento, foi realizado em Python⁹ com o auxílio da biblioteca sklearn¹⁰. Escolhemos essa linguagem e biblioteca por serem consideradas estáveis e amplamente utilizadas.

5.3.3.3.1 K-NN

O k-nearest neighbors algorithm (k-NN) é um algoritmo para reconhecimento de padrões, utilizado em modelos de clusterização e classificação (Altman 1992; Han, Kamber, and Pei 2012; Hastie, Tibshirani, and Friedman 2009). Para classificar uma determinada entrada, ele verifica quais outras entradas (daqueles usadas em seu treinamento) estão mais próximas desta nova. Então, uma votação das k entradas mais próximas decide em qual classificação esta nova entrada pertence (Han, Kamber, and Pei 2012; Hastie, Tibshirani, and Friedman 2009).

⁹ <https://www.python.org/>

¹⁰ <https://scikit-learn.org/stable/>

Para encontrarmos o melhor k, escrevemos o seguinte script:

```
from sklearn.neighbors import KNeighborsClassifier
from sklearn import metrics
Ks = 30
mean_acc = np.zeros((Ks-1))
std_acc = np.zeros((Ks-1))
for n in range(1,Ks):
    neigh = KNeighborsClassifier(n_neighbors = n).fit(X_train,y_train)
    yhat=neigh.predict(X_test)
    mean_acc[n-1] = metrics.accuracy_score(y_test, yhat)
    std_acc[n-1]=np.std(yhat==y_test)/np.sqrt(yhat.shape[0])
```

Este algoritmo avalia o treinamento de modelos k-NN com k's variando de 1 até 29. Os resultados de cada acurácia e suas médias são armazenados nos vetores presentes dentro da repetição. Após isso, inserimos estes resultados em um gráfico, demonstrado pela Figura 19, onde podemos observar a acurácia no eixo y e os valores de k no eixo x. Assim, é possível notar quais valores de k tiveram as melhores acurácias.




Figura 19: Resultados de testes para encontrar o melhor k

Se o gráfico apresentasse um resultado crescente na acurácia, em seus valores finais, iríamos estender o valor limite para nosso teste de melhor k. Porém, após o k 20, o valor da acurácia começou uma queda. Dessa forma, o melhor valor de k para nossa base de dados é o valor 12. Assim, o modelo foi então treinado com o valor de k igual a 12.

É importante destacar que esse modelo foi treinado com o objetivo de usarmos para instruir os educadores sobre a ferramenta, no período de testes finais. Para mais informações

sobre esta instrução, consulte o Capítulo 6, onde descrevemos os testes finais com a ferramenta. A acurácia final do modelo ficou em 0.8384615384615385.

5.3.3.3.2 ÁRVORE DE DECISÃO

A Árvore de Decisão é um algoritmo utilizado para classificação, baseado em relações de atributos que o algoritmo considera como mais importante, hierarquicamente (Han, Kamber, and Pei 2012; Hastie, Tibshirani, and Friedman 2009; Rokach and Maimon 2015). Para montar essas relações, o algoritmo, em sua versão mais simples, divide a base e calcula a entropia dos atributos recursivamente até montar uma árvore, com um nó pai que, baseado em diferentes condições, decide para qual filho deve caminhar. Esse processo é repetido até alcançar uma folha, que representa uma das possíveis classes do modelo treinado (Han, Kamber, and Pei 2012; Hastie, Tibshirani, and Friedman 2009; Rokach and Maimon 2015).

Escolhemos um modelo baseado na Árvore de Decisão, pois é um modelo de fácil interpretação. Podemos extrair sua árvore resultante e entender completamente como o modelo chega em suas decisões.

Como um de nossos objetivos é verificar como a simulação dos cenários afeta a percepção e questionamento dos educadores sobre os resultados dos modelos preditivos, no treino deste modelo nós fizemos uma cópia da base de dados originais e alteramos de forma que os dados fossem preconceituosos. Dessa forma, geramos um modelo preconceituoso, alterando todos os alunos que fossem negros para que sua classe de evasão fosse um ‘sim’, do contrário, a classe de evasão foi alterada para não. É importante ressaltar que fizemos esta escolha de preconceito devido ao número de casos já conhecidos e reportas sobre preconceitos raciais em IAs (Sweeney 2013).

Portanto, usaremos esse modelo para verificar se os educadores conseguirão encontrar esse preconceito nas predições da Árvore de Decisão. Então, com essa base preconceituosa, treinamos o modelo e extraímos a árvore apresentada na Figura 20. Essa árvore demonstra que o modelo realmente ficou preconceituoso.

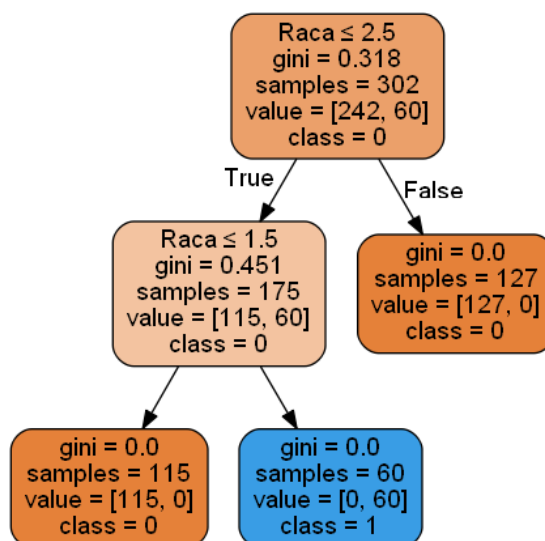


Figura 20: Árvore de Decisão final para o modelo preconceituoso

Como o treino converte as categorias em números, a categoria de raças ficou da seguinte forma: branca = 0; indígena = 1; negra = 2; outra = 3; mestiça = 4. Observando a Figura 20, vemos que a árvore irá apontar a classe 0 (não evasão) para qualquer entrada onde a raça seja menor ou igual a 1.5 e maior ou igual a 2.5. Ou seja, somente os casos onde raça for igual a 2 serão classificados com a classe 1 (com evasão).

Devido ao *overfitting*, a acurácia do modelo ficou em 1.0. Porém, já era esperado, dada nossas alterações.

5.3.3.3 REDE NEURAL

Nossa Rede Neural foi treinada com um Multilayer Perceptron (MLP) (Hastie, Tibshirani, and Friedman 2009). Esse algoritmo consiste na criação de camadas e neurônios que sofrem ativações ou não. Cada camada é enfileirada e a saída de uma camada se torna a entrada para a outra até chegar em sua última camada e apresentar a classe final (Hastie, Tibshirani, and Friedman 2009).

O MLP é considerado um modelo caixa-preta. Por isso, não podemos extrair informações precisas, como a Árvore de Decisão, para entender como o modelo chega em suas decisões. Dessa forma, é o modelo que usamos para verificar se os educadores conseguirão entender e questionar seus resultados, através das simulações (Hastie, Tibshirani, and Friedman 2009).

Para treinar o modelo, precisamos definir alguns parâmetros. Como nosso objetivo principal com esta pesquisa não envolve a busca por uma melhor acurácia, então consideramos os valores padrões da biblioteca sklearn. Os parâmetros que alteramos foram: o número de

camadas, número de neurônios em cada camada, o método para otimização dos pesos e o número máximo de iterações.

Para definir a melhor quantidade de camadas e neurônios, fizemos um pequeno algoritmo para testar todas as combinações possíveis de 3 até 27 camadas e neurônios, ao passo de 2. O algoritmo apresentado abaixo salva os resultados de cada acurácia em um vetor e a quantidade de camadas e neurônios, utilizados naquela combinação, em outro.

```
from sklearn.neural_network import MLPClassifier
df_lbfgs = pd.DataFrame(columns=['Layers', 'Accuracy'])
count = 0
for i in range(1,27,2):
    for j in range(1,27,2):
        lbfgs_clf = MLPClassifier(
            solver='lbfgs', alpha=1e-5, hidden_layer_sizes=(i, j),
            random_state=42, max_iter=5000
        ).fit(X_train, y_train)
        df_lbfgs.loc[count] = ([str(i)+'x'+str(j)], lbfgs_clf.score(X_test, y_test))
        count = count+1
```

Como é possível observar, o método para otimização dos pesos deste algoritmo é o Limited-memory Broyden–Fletcher–Goldfarb–Shanno (LBFGS). Porém, também realizamos testes com esse mesmo script, trocando o método de otimização para Stochastic Gradient Descent (SGD) e o Adaptive Moment Estimation (Adam). Essas foram nossas escolhas por serem os algoritmos presentes na biblioteca que utilizamos.

Com os valores presentes nos vetores, conseguimos gerar tabelas ordenadas pela melhor acurácia e, assim, visualizar os melhores resultados com suas quantidades de camadas e neurônios. Na Tabela 4 apresentamos os melhores resultados em cada método de otimização para comparação.

Tabela 4: Comparação entre métodos de otimização de pesos e camadas x neurônios

Método	Camadas x Neurônios	Acurácia
LBFGS	13x25	0.876923
SGD	5x23	0.869231
ADAM	5x9	0.884615

Como o ADAM teve o melhor resultado, escolhemos ele como método de otimização para os pesos, além dos valores para camadas e neurônios. Sua acurácia final, treinada com todos os dados ficou em 0.8846153846153846.

5.4 DESIGN DA INTERFACE PARA A DROP ICT

Nesta seção apresentamos como a ES pautou nosso desenvolvimento em conjunto com as expectativas e conversas com os educadores, definindo nosso espaço de design e o template de metacomunicação. Além disso, também consideramos importante destacar a interface da aplicação web, após desenvolvida, seguindo o curso natural que os educadores podem realizar para chegar em suas simulações.

5.4.1 DEFINIÇÕES PARA O ESPAÇO DE DESIGN

O emissor, como discutido anteriormente no Capítulo 2, são os desenvolvedores do sistema. Em nosso caso, o desenvolvedor busca conversar sobre a importância de questionamentos em resultados de modelos preditivos. Eu acredito que isso seja possível ao permitir que educadores consigam realizar simulações baseadas em suas experiências. Para auxiliar os usuários, o emissor acredita ser importante inserir um fluxo automático para o processo. Assim, é importante que o sistema redirecione os usuários para suas próximas etapas durante o uso. Como pode ser gerada uma quantidade diferente de cenários simulados e suas alterações podem ser mínimas, também é importante que os educadores, ao final, consigam visualizar seus testes para compará-los. Como a ferramenta é desenvolvida para educadores do EAD, o emissor também opta por utilizar signos familiares para a experiência destes educadores. Ou seja, o emissor adota o uso de jargões que necessitem uma prévia experiência do educador com o EAD.

O contexto da comunicação deve ser definido baseando-se nas reflexões sobre o ambiente de uso da ferramenta. Para a ferramenta Dropict, nossa reflexão sobre o ambiente pode ser bem complexa. Uma das características do EAD é a possibilidade de alunos e educadores desta modalidade realizarem suas tarefas em momentos e locais totalmente diferentes. Por exemplo, a ferramenta pode ser utilizada por um educador durante uma madrugada, no conforto de sua cama, através de um notebook. Por isso, a ferramenta foi desenvolvida em uma versão web, para facilitar este tipo de acesso. Entretanto, esta decisão torna necessário que o ambiente possua uma internet estável.

Para definir o receptor da mensagem, foi necessário considerar o perfil dos usuários do Dropict. Como discutido desde o início deste trabalho, o perfil alvo são educadores do EAD. Porém, é importante considerar que os emissores podem ser educadores de diferentes cursos e universidades, com diferentes experiências no uso de computadores e diferentes conhecimentos sobre modelos preditivos. Entretanto, é esperado que todos os educadores do EAD possuam conhecimento suficiente para utilizar uma ferramenta como o Dropict, devido ao uso, já esperado, de plataformas em AVA.

Para o código de comunicação escolhemos o idioma Português. Essa escolha ocorreu, pois, a ferramenta Dropict será utilizada apenas por educadores brasileiros. Em relação aos canais de comunicação, os usuários só conseguirão utilizar a ferramenta através de teclado, mouse e monitor. Esses são os canais básicos para o uso de uma aplicação web, como é o caso da ferramenta desta pesquisa. Dessa forma, sabemos que uma das limitações presentes no Dropict está na acessibilidade para pessoas com deficiência visual ou outro tipo que a impeça de visualizar informações no monitor, utilizar o teclado ou a utilização do mouse. Essa limitação ocorreu devido a restrições de cronogramas.

5.4.2 METACOMUNICAÇÃO DA FERRAMENTA DROP ICT

O próximo passo para a avaliação é analisar o template de metacomunicação. De acordo com de Souza (2005), o template da metacomunicação entre desenvolvedor-usuário é:

“Eis a minha interpretação de quem você é, o que aprendi que você tem de fazer, preferencialmente de que forma, e por quê. Eis, portanto, o sistema que conseqüentemente concebi para você, o qual você pode ou deve usar assim, a fim de realizar uma série de objetivos associados com esta minha visão”.

Este template pode ser usado para guiar na construção da metacomunicação. A primeira frase do template diz respeito ao entendimento sobre o usuário e quais suas necessidades para o uso da ferramenta. Já a segunda frase começa com uma descrição sobre o sistema, que foi gerado baseado na primeira frase. Em seguida, a frase descreve a forma de uso e termina explicando a visão do emissor sobre os objetivos que o receptor almeja.

Ao utilizar esse template e as definições descritas no Capítulo 2, nossa metacomunicação se dá na forma:

“Na minha visão você é um educador com experiência no Ensino à Distância. Você não possui, necessariamente, um conhecimento sobre o funcionamento de modelos preditivos. Porém, possui conhecimento sobre termos utilizados na EAD, bem como conhecimento técnico em informática suficiente para utilizar um Ambiente Virtual de Aprendizagem.

Aprendi que você pode discordar de resultados obtidos através de modelos desenvolvidos para realizar previsões de alunos em risco de evasão. Também aprendi que você pode utilizar o sistema em momentos de maior conforto, sem necessariamente estar em uma sala de aula, pois está acostumado a auxiliar alunos em diferentes horários e à distância, de forma assíncrona.

Eis, portanto, o Dropict. Um sistema web feito para que você consiga simular cenários baseados em casos reais de alunos em risco de evasão na EAD. Na minha visão, você prefere

que a ferramenta de ênfase para alunos considerados em risco e, que você deseja, conseguir comparar os cenários que foram gerados.

Para utilizar a ferramenta, você precisa ter acesso a um computador com monitor, teclado, mouse e internet. Porém, não será necessário nenhum conhecimento para instalação de aplicações. O sistema irá te guiar durante os passos, apresentando opções claras para que você consiga selecionar um modelo preditivo, um aluno e então simular cenários para este aluno. Como, na minha visão, você vai querer visualizar estes cenários, cada simulação é salva automaticamente enquanto você permanecer na aplicação web. O Dropict também fornece uma forma para que você volte tudo, troque de aluno ou modelo preditivo e, inclusive, ordenar ou excluir as simulações da forma que desejar.

Por fim, como acredito que você esteja preocupado com estas predições e, talvez, por outras questões éticas, a ferramenta dispõe de uma cópia completa do termo de consentimento sobre o uso da ferramenta. Também informamos que todo o processo, incluindo a utilização dos dados anonimizados que foram utilizados no desenvolvimento dos modelos preditivos, passaram por aprovação no Comitê de Ética da Universidade Federal Fluminense”.

Esta metacomunicação foi gerada a partir da ES, baseando-se em uma representação do nosso entendimento sobre como os usuários podem ver o sistema desenvolvido. Esta seção é importante para demonstrar nossa intenção com o desenvolvimento desta ferramenta e com as funções implementadas.

5.4.3 PROCESSO INTERATIVO BÁSICO



Figura 21: Tela para seleção do modelo preditivo

A interface é um componente essencial para a ferramenta, pois é através dela que o usuário realiza toda a interação com os cenários e seus resultados. Como mostra a Figura 21, ao acessar a ferramenta o usuário se depara com uma tela inicial para selecionar qual modelo preditivo será utilizado nas previsões.

Já a Figura 22 é a tela que o usuário encontra após a seleção do modelo preditivo. A ferramenta deve fornecer uma lista de alunos (A) com suas previsões de abandono, sim (vermelho) ou não (preto). Ao selecionar um aluno, a interface apresentará as informações básicas do aluno (B) e a opção de realizar simulações e previsões com o aluno selecionado (botão azul dentro de B).

The screenshot displays the 'Dropict' web application interface. On the left, a sidebar (labeled A) lists students from 'Aluno 3' to 'Aluno 18'. Each student's name is followed by a prediction status: 'NAO' (black) or 'SIM' (red). 'Aluno 7' is highlighted with a blue bar and a red 'SIM' status. The main area (labeled B) is titled 'Predição Original:' and contains several sections: 'Quantidade de Acessos' (Logins: 1511, Fórum: 213, Discussão: 0), 'Notas' (ALG: 8.01, FDW: 8.13, FMI: 9.15, EAD: 8.50, MAT: 9.80), and 'Dados Demográficos' (Idade: Entre 28 e 32, Renda Familiar: Acima de R\$3000, Estado Civil: Casado, Mora com: 4 pessoas, Raça: Negra, Sexo: Masculino, Trabalha: Integral, PC em casa: Sim). A blue button labeled 'Iniciar simulador' is located at the bottom of the main area.

Figura 22: Tela para seleção de alunos

Após selecionar o aluno, o educador finalmente se depara com o Gerador de Cenários. É através dele que os dados chegam no modelo preditivo, e também é responsável por enviar os resultados para a interface. A Figura 23 apresenta a interface deste momento, onde o educador consegue simular com o modelo preditivo e visualizar seus testes.

Dropict Início Selecionar Estudante Sobre Termos de Condição

aluno 5: **NAO**

Login: 2428 Fórum: 243 Discussão: 13

ALG	FDW	FDW	EAD	MAT
9.72	2.99	8.98	9.80	9.85

Idade: Entre 23 e 27 Raça: Mestiça

Renda Familiar: Entre R\$1426 e R\$2375 Sexo: Feminino

Est. Civil: Solteiro Trabalha: Integral

Mora com: 2 pessoas PC: Sim

Simulador: **SIM**

Login: 2428 Fórum: 243 Discussão: 13

ALG	FDW	FDW	EAD	MAT
0	0	0	0	0

Dados Demográficos

Entre 23 e 27 Mestiça

Entre R\$1426 e R\$2375 Feminino

Solteiro Integral

2 pessoas Sim

Realizar Predição

Cenário #0: **NAO** Cenário #1: **SIM**

ver mais ver mais

A B C

Figura 23: Interface onde o usuário consegue realizar e visualizar suas simulações

O gerador de cenário deve ser capaz de gerar um cenário com atributos totalmente escolhidos pelo usuário. Portanto, o usuário possui três colunas: a primeira (coluna A) são os dados originais, que o usuário não pode editar em nenhum momento. O segundo é uma cópia dos dados originais, que ele pode editar os valores (coluna B). Após a edição, quando a solicitação de previsão desses dados acontece, esse cenário editado é salvo e disponibilizado ao usuário, conforme mostrado na coluna C.

Nesse ponto, o usuário poderá visualizar qualquer um dos cenários clicando neles. Além disso, como mostra a Figura 24, a interface deve permitir que o usuário possa visualizar mais de um cenário por vez. Dessa forma, o usuário poderá comparar, em uma única visualização, a previsão real com outros cenários.

Dropict Início Selecionar Estudante Sobre Termos de Condição

aluno 5: **NAO**

Login: 2428 Fórum: 243 Discussão: 13

ALG	FDW	FDW	EAD	MAT
9.72	2.99	8.98	9.80	9.85

Idade: Entre 23 e 27 Raça: Mestiça

Renda Familiar: Entre R\$1426 e R\$2375 Sexo: Feminino

Est. Civil: Solteiro Trabalha: Integral

Mora com: 2 pessoas PC: Sim

Simulador: **NAO**

Cenário #1: **SIM**

Login: 2428 Fórum: 243 Discussão: 13

ALG	FDW	FDW	EAD	MAT
0	0	0	0	0

Dados Demográficos

Entre 23 e 27 Mestiça

Entre R\$1426 e R\$2375 Feminino

Solteiro Integral

2 pessoas Sim

Close

Cenário #0: **NAO** Cenário #1: **SIM** Cenário #2: **SIM**

ver mais ver mais ver mais

Cenário #3: **NAO**

Login: 0 Fórum: 243 Discussão: 13

ALG	FDW	FDW	EAD	MAT
10	10	5	0	0

Dados Demográficos

Entre 23 e 27 Mestiça

Acima de R\$3000 Feminino

Solteiro Integral

0 pessoas Sim

Close

Figura 24: Comparação entre dados originais e cenários simulados

Para finalizar este capítulo, é importante destacar que nosso objetivo final com esta pesquisa não envolve a criação da ferramenta Dropict. Essa ferramenta surgiu como uma consequência da necessidade de testar o uso de simulações realizadas pelos educadores, para que estes fossem inseridos no processo de decisão dos modelos preditivos. Por isso, com esta interface, esperamos que os educadores executem este processo interativo alterando as simulações na forma que desejarem. E, ao final, analisem seus cenários simulados para tentar extrair suas conclusões e comentários.

CAPÍTULO 6 – AVALIAÇÃO DAS SIMULAÇÕES

Para verificar se cenários podem auxiliar educadores do EAD a entender e questionar os resultados de IAs, nós treinamos os três modelos que descrevemos anteriormente: k-NN, Árvore de Decisão e Rede Neural. O primeiro modelo foi treinando para que demonstrássemos em um vídeo tutorial¹¹ como a ferramenta pode ser utilizada. A Árvore de Decisão e a Rede Neural são, de fato, os modelos para os educadores colocarem em teste.

Como nosso objetivo também envolve verificar se os cenários podem ser usados para questionar os resultados, decidimos treinar a Árvore de Decisão de forma preconceituosa. Alteramos os dados para o treinamento da Árvore de Decisão, de forma que todos os alunos negros estivessem com evasão positiva e todos os outros com evasão negativa.

A ideia principal destes testes foi verificar se os educadores conseguiriam identificar o viés e preconceito da Árvore de Decisão e a visão dos educadores sobre a Rede Neural, após o uso dos cenários. Por isso, disponibilizamos a ferramenta descrita anteriormente através do endereço <https://dropict.com.br/>. Assim, os testes poderiam ser executados à distância. Optamos por fazer desta forma para tentar incentivar os educadores a testarem as simulações sem que parecesse uma pressão para acertarem alguma predição e para conseguirem realizar mais simulações em um momento de sua preferência.

6.1 REQUISITOS PARA OS PARTICIPANTES

Os participantes deste estudo foram professores, mediadores ou tutores que possuíam, pelo menos, 1 ano de experiência na EAD, em cursos de nível superior. Não é um requisito que eles possuam ou não conhecimento prévio sobre modelos preditivos. Porém é importante terem conhecimento sobre o uso de Ambientes Virtuais de Aprendizado, pois 3 atributos usados no treinamento do modelo possuem relação direta com esses ambientes. Os perfis mais detalhados sobre os participantes serão apresentados na seção 6.4.1.

6.2 PROCEDIMENTOS

Todo o processo foi disponibilizado de forma que os educadores pudessem realiza-lo à distância. Optamos dessa forma devido a complicações de tempo e acreditamos que isso daria mais liberdade para que o educador executasse mais simulações nos cenários.

¹¹ <https://www.youtube.com/watch?v=vyAbM74jZAE>

O primeiro passo foi o envio dos convites e Termo de Consentimento (Apêndice E), via e-mail, para participação do estudo. Aqueles que entraram em contato demonstrando interesse receberam o Contexto do Procedimento, também por e-mail. Ou seja, todo o processo destas avaliações ocorreu à distância.

Esse Contexto do Procedimento é apresentado logo abaixo e consiste de um roteiro que contém um cenário de uso para que os educadores se envolvam e entendam melhor os testes e objetivos. Durante este cenário, os educadores deveriam responder a três questionários em momentos diferentes. Os educadores foram, então, apresentados ao seguinte roteiro:

“Antes de começar, por favor, responda este questionário sobre sua experiência no Ensino à Distância e no uso de aplicações com Inteligências Artificiais:

<https://forms.gle/NUL7fwz55ZpuzQUC9>

Cenário do estudo:

João, mediador à distância na Universidade Resgate, trabalha auxiliando os alunos dos cursos à distância de sua Universidade. Ele sempre observou o grande índice de evasão e, diversas vezes, testa soluções com a Instituição para tentar solucionar esse problema.

Agora, a Universidade onde trabalha contratou uma empresa para desenvolver Inteligências Artificiais (IAs) capazes de prever alunos que estejam em risco de evasão. Porém, João, que já tinha lido sobre IAs que aprendem erroneamente e fazem decisões equivocadas com vieses culturais, alertou a Universidade. Como a Instituição confia muito seu trabalho, eles pediram à João que testasse se essas IAs funcionam corretamente.

Para isso, a empresa desenvolveu um protótipo de testes através de simulações e um vídeo tutorial para a Universidade. A secretaria da Universidade entrou em contato com João e outros professores que se voluntariaram e passou as seguintes orientações para a realização dos testes:

(Se coloque no lugar de João e siga os mesmos passos)

1. *Assista o vídeo tutorial sobre a ferramenta:*

<https://www.youtube.com/watch?v=vyAbM74jZAE>

2. *Acesse o site da ferramenta: <https://dropict.com.br/>*

3. *Escolha a IA Árvore de Decisão e um aluno com predição "Sim". Utilize o simulador para alterar seus dados de forma que sua predição mude.*

4. *Volte, selecione um aluno com predição "Não" e faça simulações para alterar seu resultado.*

5. *Se desejar, sinta-se à vontade para realizar mais testes com outros alunos utilizando a IA Árvore de Decisão*
6. *Após os testes com a IA Árvore de Decisão, responda a este questionário:*
<https://forms.gle/RqT5zfxZed9xSThe9>
7. *Volte no Início do site, escolha a IA Rede Neural e um aluno com predição "Sim". Utilize o simulador para alterar seus dados de forma que sua predição mude.*
8. *Volte, selecione um aluno com predição "Não" e faça simulações para alterar seu resultado.*
9. *Se desejar, sinta-se à vontade para realizar mais testes com outros alunos utilizando a IA Rede Neural*
10. *Após os testes com a IA Rede Neural, responda a este questionário:*
<https://forms.gle/q2qnzbsLmxu3WhSH9>

Então, como é possível notar através do roteiro, cada educador respondeu três questionários. O primeiro relacionado a sua experiência pessoal com EAD e o uso de IAs (Apêndice C). Já os outros dois questionários estavam relacionados com os testes feitos utilizando a Árvore de Decisão e a Rede Neural (Apêndice D).

Assim, as perguntas para o primeiro questionário tinham o objetivo de coletar informações sobre o perfil do educador e suas experiências com aplicações que utilizam modelos preditivos. Já o segundo e terceiro questionário estão relacionados ao próprio teste da ferramenta com dois modelos diferentes. Estes questionários eram idênticos, trocando apenas os nomes dos modelos preditivos, entre Árvore de Decisão e Rede Neural.

No total, três educadores realizaram o teste completamente. A seguir discutimos os resultados obtidos. Vale ressaltar que as perguntas dos questionários podem ser visualizadas ao final deste trabalho, nos Apêndices.

6.3 ANÁLISES

Para analisar os resultados das avaliações conduzidas pelos educadores, nós coletamos os dados dos formulários mencionados na seção anterior. Através destes questionários, conseguimos coletar dados textuais e opções objetivas escolhidas pelos educadores. Ou seja, temos suas escolhas e comentários sobre a experiência.

Como se trata de uma avaliação qualitativa, é importante separar a experiência de cada educador e considera-la fora de um contexto estatístico. Por isso, ao analisar, seguimos as observações e coletas em cada educador individualmente. Ao analisar os comentários de cada

educador, extraímos informações combinando com as repostas que estes derem em suas outras perguntas. O mesmo ocorreu quando as perguntas tinham como respostas opções objetivas. Ao final da análise, separados os resultados por tipo de questionário. Ou seja, teremos os resultados sobre os perfis dos educadores, os resultados em relação ao uso da Árvore de Decisão e outra seção para os resultados relacionados ao uso da Rede Neural.

6.4 RESULTADOS

Nesta seção discutimos os resultados das avaliações conduzidas pelos educadores. Esses resultados são discutidos com base nas perguntas dos questionários e, no capítulo seguinte, voltaremos a essa discussão com base em nossos objetivos principais. Para todos os dados que não sejam comentários, considerem três respostas, pois três educadores fizeram o processo e responderam os três questionários.

6.4.1 PERFIL DOS EDUCADORES

Os três educadores que realizaram todo o teste representavam quatro cursos e três universidades diferentes: Administração - UFRRJ; Computação-UFF; Geografia-UERJ; Pedagogia-UFRRJ. Suas experiências com EAD variaram entre 3 e 6 anos. Estas três pessoas informaram utilizar diferentes aplicativos que possuem IAs. Dentre os aplicativos, todos utilizam serviço de e-mail com detecção automática de SPAM, e alguns utilizam IAs de assistência e/ou ajudas.

Além disso, todos se disseram satisfeitos com as respostas dadas por essas IAs. Porém, quando perguntados sobre a confiança nas respostas, tivemos três respostas diferentes. Dois, dos três educadores, realmente confiam nas IAs que utilizam. Porém, uma pessoa disse confiar pouco e, ao descrever o motivo para a falta de confiança, comentou:

P3: “Confio de modo objetivo, por exemplo, quero chegar até um determinado local utilizando o Google Maps, ao me aproximar do local o App me indica um lugar para almoçar, não confio na indicação do App, pois sei que uma diversidade de fatores que eu não domino estão em jogo aí.”

Essas diferentes respostas, desde os cursos, universidades as quais pertencem, até mesmo na confiança das respostas das IAs, nos mostra que os testes foram realizados por perfis de uma mesma área, porém com visões e experiências diferentes. Para completar, ainda tivemos uma pessoa que já identificou vieses ou preconceitos nas respostas de IAs, comentando sobre um redirecionamento do Google para que ela não passasse no caminho de uma comunidade:

P3: *“Novamente, o Google Maps, estava indo a um determinado local, no qual conhecia o caminho mais viável (rápido e seguro), mas não conhecia exatamente o número do local, então utilizei o App, que sugeriu que eu fizesse um caminho mais distante do que eu iria fazer, ao fazê-lo, percebi que o App fez um caminho entorno a uma comunidade periférica, na qual eu teria passado por dentro.”*

6.4.2 MODELO PREDITIVO: ÁRVORE DE DECISÃO

Ao utilizar o modelo construído com o algoritmo Árvore de Decisão, gostaríamos de observar se os educadores iriam encontrar o preconceito que existia dentro do modelo. No início, como a primeira pergunta era para dizer se o educador concorda ou não com as respostas do modelo, todos disseram não concordar. Nesta resposta, tivemos dois comentários.

P3: *“Não concordo com a lógica que define a situação do aluno. Acho o esquema reproduz um preconceito racial. Por exemplo, na simulação com o aluno 28, apenas pelo fato de eu ter mudado de raça negra para branca ele saiu da condição de potencial aluno para evasão. O mesmo ocorreu com o aluno 3, no qual mudei de raça branca para negra e ele simplesmente se tornou um aluno com potencial de evasão confirmado. Dessa maneira, em ambas as situações, embora os alunos estejam nas mesmas condições, apenas a diferença entre raça branca e negra define a condição de evasão.”*

P2: *“Um dos exemplos de aluno com ótimas notas e muitas interações na plataforma com indicação de evasão. Outro pelo contrário sem risco.”*

P3 começou descrevendo todo o problema que encontrou nas predições e, além disso, pontuou claramente a identificação do preconceito presente no modelo. Porém, P2, parece não ter concordado simplesmente por não ter conseguido alterar a predição com os atributos que ele considerava importante. As próximas perguntas apenas reforçaram essas inferências. P3 identificou dois atributos utilizados para a predição: renda familiar e raça. P1 e P2 não marcaram, mas P2 explicou o motivo.

P3: *“com os testes que eu fiz, posso considerar que essas variáveis são as mais consideráveis em relação ao resultado final”*

P2: *“Não encontrei nada que mudou a predição. Fiz escolhas totalmente inversas e não alterou.”*

P2 claramente não conseguiu identificar o preconceito. Ao que parece, devido a tentativas de alterar apenas os atributos notas e acessos. Como P1 não comentou ou marcou nada, não sabemos onde foi a dificuldade. Porém, vale lembrar que P1 também respondeu a primeira pergunta não concordando com os resultados do modelo.

Por fim, quando perguntados se o uso das simulações e cenários foi útil para a compreensão e questionamento dos resultados, P2 e P3 responderam que ajudou muito, enquanto P1 respondeu indiferença. Ainda tivemos um comentário de P3 justificando sua escolha neste quesito.

P3: *“Contribuíram na minha compreensão de que, embora as variáveis ou categorias utilizadas tenham alguma relação com o resultado que está sendo buscado, essas variáveis sociais e econômicas, consideradas isoladamente, de modo quantitativo, não apresentam resultados concretos da realidade.”*

6.4.3 MÓDULO PREDITIVO: REDE NEURAL

Ao utilizar o modelo construído com o algoritmo MLP, gostaríamos de observar se os educadores iriam identificar e conseguir questionar os resultados da Rede Neural. Como não conhecemos as motivações que o modelo preditivo usa para chegar em suas conclusões, estamos mais interessados em estudar se os educadores conseguiriam questionar esses resultados de alguma forma.

No início, como a primeira pergunta era para dizer se o educador concorda ou não com as respostas do modelo, tivemos uma resposta diferente para cada educador. P1, ao concordar, explicou o motivo. Ou seja, o educador concorda, pois é baseado em atributos que P1 considera realmente impactantes na evasão do EAD. Já P3, disse exatamente o contrário.

P1: *“As predições da Rede Neural com relação ao aluno ‘Sim’ foram baseadas na quantidade de acesso e nota e ao aluno ‘Não’ foi baseado na nota.”*

P3: *“Acredito que o cruzamento dos dados não corresponde às verdadeiras situações reais que definem a motivação da evasão.”*

Quando perguntamos aos educadores sobre os atributos que eles encontraram como importantes para os resultados, P1 e P2 marcaram a quantidade de acesso à plataforma e aos fóruns de discussão. P1 também verificou notas e renda familiar. No entanto, P2 e P3 não marcaram outros atributos. Esses resultados podem indicar confusão entre os educadores, ao contrário do que esperávamos. No entanto, todos concordaram com a utilidade dos cenários para questionar a IA, embora P3 discordasse dos resultados.

6.5 LIMITAÇÕES DA ANÁLISE

Devido a forma como construímos nosso ambiente de simulações e como o estudo foi conduzido, a única maneira de analisarmos as simulações dos educadores seria se gravássemos qualquer simulação que o educador fez e associássemos essas gravações ao IP ou outra identificação da pessoa. Porém, por questões éticas quanto ao armazenamento destas informações, essa funcionalidade não foi implementada na ferramenta.

Isso significa que a limitação desta análise se refere a falta de comparação das simulações com o que cada educador responde nos questionários. A adição destas simulações associadas a cada educador poderia nos dar *insights* sobre as tentativas e respostas de cada um. Entretanto, isso não prejudica nossas conclusões sobre o estudo, pois elas estão mais relacionadas com a opinião direta dos educadores quanto o uso das simulações como forma de questionamento e identificação de problemas nas IAs.

CAPÍTULO 7 – CONCLUSÕES

7.1 ATÉ QUE PONTO OS USUÁRIOS CONSEGUIRAM IDENTIFICAR PRECONCEITOS NO USO DA ÁRVORE DE DECISÃO?

Quando discutimos os resultados das avaliações na Árvore de Decisão, vemos que pode existir potencial no uso de simulações e cenários para a identificação de preconceitos nas IAs. No entanto, para que isso ocorra efetivamente, seria necessário estudar outras maneiras de fazer essas simulações.

Podemos dizer isso porque tivemos um caso de sucesso em que o educador encontrou preconceito. No entanto, ele só o encontrou devido à sua própria experiência com o uso de outras IAs, onde ele já havia identificado preconceitos. Então, a partir de sua experiência, o educador realizou simulações com o atributo onde havia racismo.

No caso de outros educadores, eles identificaram predições erradas. No entanto, eles não conseguiram identificar o racismo. Em um dos comentários, ficou claro que o educador não conseguiu identificar os atributos que afetaram as predições da Árvore de Decisão.

7.2 ATÉ QUE PONTO A SIMULAÇÃO DE CENÁRIOS PERMITE O QUESTIONAMENTO DOS RESULTADOS EM MODELOS PREDITIVOS NO CONTEXTO DE EVASÃO NO EAD?

Quando analisamos, não apenas os resultados das avaliações na Rede Neural, mas também na Árvore de Decisão, podemos ver alertas claros levantados pelos educadores, em todos os casos. Um dos educadores afirmou que as predições estavam erradas porque, quando ele mudou atributos que considera importantes, a IA não fez predições diferentes. Outro disse que os resultados estavam errados devido a uma mudança nos atributos socioeconômicos que resultaram em uma previsão diferente, argumentando que esses atributos não devem ser considerados, embora esses alertas variem de acordo com a experiência e a visão de cada educador.

Além disso, os educadores concordaram que o uso de simulações trouxe reflexões e permitiu questionamentos. Apesar disso, também ficou claro que os educadores não conseguiram entender as causas relacionadas às predições da Rede Neural.

7.3 DISCUSSÃO FINAL

Trabalhos já citados nesta pesquisa, como de Joh (2016), confirmam que estamos vivendo com soluções de IA que tomam decisões e mostram resultados culturalmente tendenciosos

chegando, até mesmo, ao preconceito racial¹² e sexual¹³. Assim, precisamos cada vez mais de maneiras para questionar os resultados destes modelos. Por esse motivo, apresentamos uma pesquisa que investigou o uso de simulações de cenários para permitir que educadores, sem conhecimento técnico sobre IA, questionem os resultados dos modelos previstos.

Os principais resultados sugerem que o uso destas simulações pode funcionar para esse questionamento. Os educadores conseguiram concordar e discordar com os resultados, se embasando e descrevendo suas experiências como critérios de aceitação ou não dos resultados. De acordo com seus comentários, isso foi possível pois eles conseguiram visualizar os dados dos alunos que estavam sendo avaliados e fazer suposições com os modelos preditivos. De fato, não podemos concluir que o uso das simulações permitiu que os educadores entendessem as motivações por trás das decisões dos modelos, mas podemos concluir que essas simulações permitiram que o educador fosse o tomador final da decisão.

Essa inserção dos educadores no processo de decisão permitiu, até mesmo, que um educador conseguisse encontrar um preconceito correto na Árvore de Decisão. Sabemos que este educador já tinha um histórico de preconceitos no uso de IAs, porém, sem nenhum conhecimento técnico sobre o assunto, apenas com sua experiência de vida e as simulações, ele conseguiu encontrar o problema. Isso demonstra que a simulação dos cenários tem potencial para identificação de problemas raciais nos modelos preditivos, no contexto em que analisamos.

Assim, pelo que aprendemos até agora, concluímos que as simulações podem ter o potencial de questionar resultados e até identificar preconceitos. No entanto, é necessário realizar uma investigação mais aprofundada para verificar se o uso dessas simulações se mostra realmente útil para um número significativo de usuários.

7.4 LIMITAÇÕES DA PESQUISA

Da mesma forma que o MSL e a análise, nossa pesquisa também possui limitações. As mais claras estão relacionadas com o fato de toda a pesquisa ter sido conduzida em um único contexto cultural do estado do Rio de Janeiro, no Brasil. Ou seja, todos os educadores e os pesquisadores envolvidos nessa pesquisa estão inseridos no mesmo contexto cultural, em termos de localização do estado e país.

Além disso, temos uma limitação clara também quanto os modelos utilizados no processo. Toda nossa análise foi conduzida baseado em resultados providos por dois modelos

¹² <https://www.theguardian.com/inequality/2017/aug/08/rise-of-the-racist-robots-how-ai-is-learning-all-our-worst-impulses>

¹³ <https://www.nytimes.com/2018/02/09/technology/facial-recognition-race-artificial-intelligence.html>

preditivos, onde cada um deles possuía um objetivo diferente. Por isso, nossas conclusões referentes ao uso de simulações para identificação de preconceitos em modelos preditivos de evasão no EAD, só podem ser consideradas para um modelo construído através do algoritmo de Árvore de Decisão. Não sabemos, por exemplo, se essas análises se comportariam de forma semelhante com outros modelos, mesmo que os mesmos educadores executassem o mesmo processo.

Outro fator importante para nortear até onde as conclusões deste trabalho devem ser consideradas é a interface de nossa ferramenta. Por mais que tenhamos utilizado uma técnica conceituada como a ES, é preciso reforçar que nossa interface interativa não é, necessariamente, a melhor possível. Pequenas alterações na forma como os usuários interagem, escolhem os valores para os atributos ou visualizam os cenários criados, poderiam trazer grandes impactos nas considerações finais de cada educador.

Entretanto, mesmo com as limitações apresentadas, nossas conclusões reforçam, não só um problema atual, como também uma alternativa que se demonstra promissora para lidar com este problema. Ainda assim, é necessário fazer uma análise mais profunda para descobrir se esses achados se mantêm com um número mais significativo de educadores e com uma maior variedade cultural.

7.5 TRABALHOS FUTUROS

De acordo com o próprio relato de um dos educadores, as simulações o ajudaram muito na investigação dos resultados gerados pelos modelos preditivos. As outras duas pessoas também concordaram que o uso das simulações as ajudou, mas não deixaram comentários.

Então, pelo que foi discutido até o momento, concluímos que as simulações podem ter potencial para o questionamento dos resultados e, até mesmo, para a identificação dos preconceitos. Ainda assim, como discutido anteriormente, é necessária uma investigação maior, com mais educadores envolvidos, para verificar se o uso dessas simulações se demonstra útil com base estatística.

Além disso, toda a ferramenta precisa de um estudo para sua própria interface. Precisa-se realizar estudos que identifiquem rupturas e ajudem os educadores em suas simulações. Por exemplo, será que podemos guiar os educadores para testar atributos específicos? Qual seria a melhor forma para fazer isso?

Também precisamos realizar estudos que identifiquem interrupções e ajudem os educadores em suas simulações. Por exemplo, podemos orientar educadores para avaliar

atributos específicos? Qual seria a melhor forma de fazer isso? Se tivermos uma melhor interação e orientação, ela poderia ser usada para entender os resultados de uma rede neural?

Por último, é importante pesquisar o uso de simulações, não só neste contexto de EAD, como também em outros contextos. Pessoas que trabalham em outros segmentos, com motivações diferentes, também iriam demonstrar indícios similares aos que concluímos neste estudo? Além do contexto, também é preciso verificar como a alteração dos modelos preditivos reflete nos resultados. Se alterarmos os modelos preditivos por outros, qual seriam os resultados?

Esta pesquisa conclui reforçando o potencial de simulações como forma para questionamento de modelos preditivos para identificação de alunos em risco de evasão no EAD. Porém, além de nossa contribuição presente, também deixamos perguntas que podem auxiliar cada vez mais na inserção de nós, pessoas, nas decisões dos modelos preditivos.

REFERÊNCIAS

- Akoka, Jacky, Isabelle Comyn-Wattiau, and Nabil Laoufi. 2017. "Research on Big Data – A Systematic Mapping Study." *Computer Standards and Interfaces* 54: 105–15. <https://linkinghub.elsevier.com/retrieve/pii/S0920548917300211> (February 20, 2020).
- Albrecht, Jan Philipp. 2016. "How the GDPR Will Change the World." *European Data Protection Law Review* 2(3): 287–89.
- Alpaydm, Ethem. 2010. *Introduction to Machine Learning*. eds. Thomas Dietterich, Christopher Bishop, David Heckerman, Michael Jordan, and Michael Kearns. The MIT Press. https://kkpatel7.files.wordpress.com/2015/04/alpaydin_machinelearning_2010.pdf.
- Altman, N. S. 1992. "An Introduction to Kernel and Nearest-Neighbor Nonparametric Regression." *American Statistician* 46(3): 175–85.
- Anderson, Terry. 2008. Theory and practice of online learning *The Theory and Practice of Online Learning*. 2nd ed. Athabasca University Press. http://biblioteca.ucv.cl/site/colecciones/manuales_u/99Z_Anderson_2008-Theory_and_Practice_of_Online_Learning.pdf.
- Anderson, Terry, and Denise Whitelock. 2004. "The Educational Semantic Web: Visioning and Practicing the Future of Education." *Journal of Interactive Media in Education* 1(1): 1–15. <http://jime.open.ac.uk/articles/10.5334/2004-1/> (September 24, 2018).
- Andifes, A, A Abruem, and S SESu/MEC. 1996. "Diplomação, Retenção e Evasão Nos Cursos de Graduação Em Instituições de Ensino Superior Públicas." *Revista Da Avaliação Da Educação Superior* 1(2): 1–36.
- Baxter, Jacqueline Aundree. 2012. "Who Am I and What Keeps Me Going? Profiling the Distance Learning Student in Higher Education." *The International Review of Research in Open and Distributed Learning* 13(4): 107. <http://www.irrodl.org/index.php/irrodl/article/view/1283>.
- Bertsekas, Dimitri P. 2012. *Dynamic Programming and Optimal Control, Vol. II*. 4th ed.
- Bielschowsky, Carlos Eduardo. 2017. "Consórcio Cederj: A História Da Construção Do Projeto." *EaD em FOCO* 7(2). <http://eademfoco.cecierj.edu.br/index.php/Revista/article/view/652>.
- Buchinger, Diego, Gustavo Andriolli de Siqueira Cavalcanti, and Marcelo Da Silva Hounsell. 2014. "Mecanismos de Busca Acadêmica: Uma Análise Quantitativa." *Revista Brasileira de Computação Aplicada* 6(1): 108–20.
- Burck, Charlotte. 2005. "Comparing Qualitative Research Methodologies for Systemic Research: The Use of Grounded Theory, Discourse Analysis and Narrative Analysis." *Journal of Family Therapy* 27(3): 237–62.
- Cai, Yuzhuo, and Wenge Guo. 2006. "Responses of Chinese Higher Education to the Information Society." *E-Learning and Digital Media* 3(3): 353–60. <http://journals.sagepub.com/doi/10.2304/elea.2006.3.3.353> (September 22, 2018).
- Caregnato, Rita, and Regina Mutti. 2006. "Pesquisa Qualitativa: Análise de Discurso versus Análise de Conteúdo." *Texto Contexto Enfermagem* 15(6): 679–84.
- Chen, Yuanzhe et al. 2017. "DropoutSeer: Visualizing Learning Patterns in Massive Open

- Online Courses for Dropout Reasoning and Prediction.” In *2016 IEEE Conference on Visual Analytics Science and Technology, VAST 2016 - Proceedings*, , 111–20.
- Chmielewski, Michal R., and Jerzy W. Grzymala-Busse. 1996. “Global Discretization of Continuous Attributes as Preprocessing for Machine Learning.” *International Journal of Approximate Reasoning* 15: 319–31.
- Cooper, I Diane. 2016. “What Is a ‘Mapping Study?’” *Journal of the Medical Library Association : JMLA* 104(1): 76–78. <http://www.ncbi.nlm.nih.gov/pubmed/26807058>.
- Creswell, John W. 2007. 9 Qualitative Health Research *Qualitative Inquiry & Research Design, Choosing Among Five Approaches*. https://books.google.com.br/books/about/Qualitative_Inquiry_and_Research_Design.htm?id=OJYEBdtkxq8C&redir_esc=y (December 28, 2018).
- Creswell, John W. 2003. *Research Design: Qualitative, Quantitative, and Mixed Methods Approaches*. 2nd ed. Thousand Oaks, CA: Sage. https://www.researchgate.net/profile/Daliborka_Luketic/publication/320521456_Nacrt_i_istrzivanje_kvalitativni_kvantitativni_i_mjesoviti_pristupi/links/5a8ad103aca272017e62aa7a/Nacrt-istrzivanje-kvalitativni-kvantitativni-i-mjesoviti-pristupi.pdf.
- Dash, M., and H. Liu. 1997. “Feature Selection for Classification.” *Intelligent Data Analysis* 1(3): 131–56.
- Derneval, Diego, Jorge A. P. de M. Coelho, and Ig Bittencourt. 2019. “Mapeamento Sistemático e Revisão Sistemática Da Literatura Em Informática Na Educação.” In *Metodologia de Pesquisa Em Informática Na Educação: Abordagem Quantitativa de Pesquisa*,.
- DiCicco-Bloom, Barbara, and Benjamin F Crabtree. 2006. “The Qualitative Research Interview.” *Medical Education* 40(4): 314–21. <http://doi.wiley.com/10.1111/j.1365-2929.2006.02418.x>.
- Diver, Paul, and Ignacio Martinez. 2015. “MOOCs as a Massive Research Laboratory: Opportunities and Challenges.” *Distance Education* 36(1): 5–25. <http://www.tandfonline.com/doi/full/10.1080/01587919.2015.1019968> (September 23, 2018).
- Dosilovic, Filip Karlo, Mario Brcic, and Nikica Hlupic. 2018. “Explainable Artificial Intelligence: A Survey.” *2018 41st International Convention on Information and Communication Technology, Electronics and Microelectronics, MIPRO 2018 - Proceedings*: 210–15.
- Frazelle, Sarah, and Rhonda Barton. 2006. “Implementing Early Warning Systems.” *National Association of Secondary School Principals* 8: 1–8.
- Frazelle, Sarah, and Aisling Nagel. 2015. *A Practitioner’s Guide to Implementing Early Warning Systems*. <http://ies.ed.gov/>.
- Gill, P, K Stewart, E Treasure, and B Chadwick. 2008. “Methods of Data Collection in Qualitative Research: Interviews and Focus Groups.” *British Dental Journal* 204(6): 291–95. <http://www.nature.com/articles/bdj.2008.192>.
- Han, Jiawei, Micheline Kamber, and Jian Pei. 2012. *Data Mining: Concepts and Techniques*.
- Hanson, Janet. 2009. “Displaced but Not Replaced: The Impact of e-Learning on Academic Identities in Higher Education.” *Teaching in Higher Education* 14(5): 553–64. <http://www.tandfonline.com/doi/abs/10.1080/13562510903186774> (December 28, 2018).

- Harasim, Linda. 2000. "Shift Happens: Online Education as a New Paradigm in Learning." *Internet and Higher Education* 3(1-2): 41-61. <http://linkinghub.elsevier.com/retrieve/pii/S1096751600000324> (September 22, 2018).
- Hastie, Trevor, Robert Tibshirani, and Jerome Friedman. 2009. *The Elements of Statistical Learning The Elements of Statistical Learning Data Mining, Inference, and Prediction*.
- Holzinger, Andreas et al. 2017. "A Glass-Box Interactive Machine Learning Approach for Solving NP-Hard Problems with the Human-in-the-Loop." *arXiv*.
- Hu, Ya Han, Chia Lun Lo, and Sheng Pao Shih. 2014. "Developing Early Warning Systems to Predict Students' Online Learning Performance." *Computers in Human Behavior* 36: 469-78.
- INEP. 2018. *Censo Da Educação Superior 2018*.
- Isaacs, Shafika. 2014. *The ELearning Africa Report 2013*. <http://er.dut.ac.za/handle/123456789/44>.
- Joh, Elizabeth E. 2016. "The New Surveillance Discretion: Automated Suspicion, Big Data, and Policing." *Harvard Law & Policy Review* 10: 15-42. <http://perma.cc/U2TB-RYNW>].
- Jordan, Katy. 2014. "Initial Trends in Enrolment and Completion of Massive Open Online Courses." *The International Review of Research in Open and Distributed Learning* 15(1). <http://www.irrodl.org/index.php/irrodl/article/view/1651>.
- Jordan, Michael I., and Christopher M. Bishop. 2004. *Neural Networks*. Chapman & Hall/CRC Press LLC.
- Kerber, Randy. 1992. "ChiMerge: Discretization of Numeric Attributes." In *AAAI'92: Proceedings of the Tenth National Conference on Artificial Intelligence*, , 123-28.
- Kim, Tae Wan, and Bryan R Routledge. 2018. "Informational Privacy, A Right to Explanation, and Interpretable AI." In *2nd IEEE Symposium on Privacy-Aware Computing, PAC 2018*, , 64-74.
- Kline, Ronald R. 2011. "Cybernetics, Automata Studies, and the Dartmouth Conference on Artificial Intelligence." *IEEE Annals of the History of Computing* 33(4): 5-16.
- Knowles, Jared E. 2015. "Of Needles and Haystacks: Building an Accurate Statewide Dropout Early Warn-Ing System in Wisconsin." *Journal of Educational Data Mining* 7(3).
- Kotsiantis, S B, and P E Pintelas. 2004. "A Decision Support Prototype Tool for Predicting Student Performance in an ODL Environment." *Interactive Technology and Smart Education* 1(4): 253-64. <http://www.emeraldinsight.com/doi/10.1108/17415650480000027> (December 28, 2018).
- Kumar, Jain Yogendra, and Bhandare Santosh Kumar. 2011. "Min Max Normalization Based Data Perturbation Method for Privacy Protection." *International Journal of Computer & communication Technology* 2(8): 45-50. https://www.researchgate.net/publication/312910769_Min_max_normalization_based_data_perturbation_method_for_privacy_protection.
- Kumar, Vipin, and Sonajharia Minz. 2014. "Feature Selection: A Literature Review." *Smart Computing Review* 4(3).
- Langley, Pat. 1994. *Selection of Relevant Features in Machine Learning*.
- Larus, James et al. 2018. *When Computers Decide: European Recommendations on Machine-Learned Automated Decision Making*. <https://dl.acm.org/citation.cfm?id=3185595>

- (December 28, 2018).
- Lee, Sunbok, and Jae Young Chung. 2019. "The Machine Learning-Based Dropout Early Warning System for Improving the Performance of Dropout Prediction." *Applied Sciences* 9(15).
- Liang, Jiajun, Chao Li, and Li Zheng. 2016. "Machine Learning Application in MOOCs: Dropout Prediction." In *2016 11th International Conference on Computer Science & Education (ICCSE)*, IEEE, 52–57. <http://ieeexplore.ieee.org/document/7581554/> (December 28, 2018).
- Liu, Huan, and Rudy Setiono. 1995. "Chi2: Feature Selection and Discretization of Numeric Attributes." In *Proceedings of the International Conference on Tools with Artificial Intelligence*, , 388–91.
- Mackenzie, Noella, and Sally Knipe. 2006. "Research Dilemmas: Paradigms, Methods and Methodology." *Issues in Educational Research*: 193–205. <https://eric.ed.gov/?id=EJ806133> (December 28, 2018).
- Matukhin, Dmitry, and Elena Zhitkova. 2015. "Implementing Blended Learning Technology in Higher Professional Education." *Procedia - Social and Behavioral Sciences* 206: 183–88. <https://www.sciencedirect.com/science/article/pii/S1877042815051848> (September 24, 2018).
- May, Katharyn Antle. 2013. "Interview Techniques in Qualitative Research: Concerns and Challenges." In *Qualitative Nursing Research: A Contemporary Dialogue*, , 188–201. [https://books.google.com.br/books?hl=pt-BR&lr=&id=8245DQAAQBAJ&oi=fnd&pg=PA188&dq=May,+K.+\"Interview+techniques+in+qualitative+research:+concerns+and+challenges\".+Morse+J+M.+pp+187-201.+1991.&ots=YPzySbjhJL&sig=Rfmp8gj5I1zf6cElAg_poMSmwEE](https://books.google.com.br/books?hl=pt-BR&lr=&id=8245DQAAQBAJ&oi=fnd&pg=PA188&dq=May,+K.+\) (December 27, 2018).
- Mayer, Richard E. 2009. *Multimedia Learning*. Cambridge University Press. www.cambridge.org.
- McNamara, Carter. 2009. "General Guidelines for Conducting Research Interviews." <https://managementhelp.org/businessresearch/interviews.htm> (December 10, 2018).
- Means, Barbara et al. 2009. *Evaluation of Evidence-Based Practices in Online Learning: A Meta-Analysis and Review of Online Learning Studies*. www.ed.gov/about/offices/list/oepdp/ppss/reports.html.
- Mertens, Donna M. 2005. *Research and Evaluation in Education and Psychology : Integrating Diversity with Quantitative, Qualitative, and Mixed Methods*. Sage Publications. <https://eric.ed.gov/?id=ED500340> (December 28, 2018).
- Miller, Tim. 2017. "Explanation in Artificial Intelligence: Insights from the Social Sciences." <http://arxiv.org/abs/1706.07269>.
- Mitchell, Tom M. 1999. "Machine Learning and Data Mining." *Communications of the ACM* 42(11): 30–36.
- Monteiro, Renato Leite (INSTITUTO IGARAPÉ). 2018. *Existe Um Direito à Explicação Na Lei Geral de Proteção de Dados Do Brasil?*
- Moore, Joi L, Camille Dickson-Deane, and Krista Galyen. 2011. "E-Learning, Online Learning, and Distance Learning Environments: Are They the Same?" *Internet and Higher Education* 14: 129–35.

<https://pdfs.semanticscholar.org/538b/c898be34b623600ee496f079b32febf21a50.pdf>
(September 21, 2018).

- Nagrega, Saurabh, John Z Dillon, and Nitesh V Chawla. 2017. "MOOC Dropout Prediction: Lessons Learned from Making Pipelines Interpretable." In *Proceedings of the 26th International Conference on World Wide Web Companion*, WWW '17 Companion, Republic and Canton of Geneva, Switzerland: International World Wide Web Conferences Steering Committee, 351–59. <https://doi.org/10.1145/3041021.3054162>.
- Niemi, David, and Elena Gitin. 2012. "Using Big Data to Predict Student Dropouts: Technology Affordances for Research." *International Association for Development of the Information Society*. <https://eric.ed.gov/?id=ED542777>.
- Ortigosa, Alvaro et al. 2019. "From Lab to Production: Lessons Learnt and Real-Life Challenges of an Early Student-Dropout Prevention System." *IEEE Transactions on Learning Technologies* 12(2): 264–77.
- Pappano, Laura. 2012. "The Year of the MOOC." <https://www.nytimes.com/2012/11/04/education/edlife/massive-open-online-courses-are-multiplying-at-a-rapid-pace.html> (December 8, 2018).
- Patro, S.Gopal Krishna, and Kishore Kumar sahu. 2015. "Normalization: A Preprocessing Stage." *Iarjset*: 20–22.
- Petersen, K., R. Feldt, and S. Mujtaba. 2008. "Systematic Mapping Studies in Software Engineering." *Proceedings of the 12th International Conference on Evaluation and Assessment in Software Engineering*: 1--10. www.splc.net.
- Phipps, Ronald, and Jamie Merisotis. 1999. "What's the Difference? A Review of Contemporary Research on the Effectiveness of Distance Learning in Higher Education." *Institute for Higher Education Policy*: 49. <http://www.ihep.com>.
- Ramírez-Gallego, Sergio et al. 2016. "Data Discretization: Taxonomy and Big Data Challenge." *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery* 6(1): 5–21.
- Reitermanova, Zuzana. 2010. *Data Splitting*.
- Ribeiro, Elvia Nunes, Gilda Aquino, and Alzino Furtado. 2007. "A Importância Dos Ambientes Virtuais de Aprendizagem Na Busca de Novos Domínios Da Ead." *Learning*.
- Rokach, Lior, and Oded Maimon. 2015. *Data Mining with Decision Trees: Theory and Applications*.
- Sesabo, Jennifer Kasanda, Rashid Mfaume, and Dominik T. Msabila. 2015. "Opportunities and Challenges in Implementing Distance Learning and E-Learning." In *Handbook of Research on Educational Technology Integration and Active Learning*, , 329–45. <http://services.igi-global.com/resolvedoi/resolve.aspx?doi=10.4018/978-1-4666-8363-1.ch016> (September 22, 2018).
- Silverman, David. 2017. *Qualitative Research Methods for Media Studies Doing Qualitative Research*.
- Snyder, Thomas D, Sally A Dillow, and Charlene M Hoffman. 2009. National Center for Education Statistics *Digest of Education Statistics, 2008. NCES 2009-020*. <https://nces.ed.gov/pubs2009/2009020.pdf>.
- Solomonoff, R. J. 1985. "The Time Scale of Artificial Intelligence: Reflections on Social Effects." *Human Systems Management* 5(2): 149–53.

- de Souza, Clarisse S. 1993. "The Semiotic Engineering of User Interface Languages." *International Journal of Man-Machine Studies* 39(5): 753–73.
- de Souza, Clarisse Sieckenius. 2005. *The Semiotic Engineering of Human-Computer Interaction*. The MIT Press.
- Sweeney, Latanya. 2013. "Discrimination in Online Ad Delivery." *SSRN Electronic Journal*.
- Union, European. 2018. *Recital 71 - Profiling / General Data Protection Regulation (GDPR)*. <https://gdpr-info.eu/recitals/no-71/>.
- Vitiello, Massimo et al. 2017. "MOOC Dropouts: A Multi-System Classifier." In *European Conference on Technology Enhanced Learning*, , 300–314. http://link.springer.com/10.1007/978-3-319-66610-5_22 (December 28, 2018).
- W Turner, Daniel. 2010. "Qualitative Interview Design: A Practical Guide for Novice Investigators." *Qualitative Report* 15.
- Wachter, Sandra, Brent Mittelstadt, and Luciano Floridi. 2017. "Why a Right to Explanation of Automated Decision-Making Does Not Exist in the General Data Protection Regulation." *International Data Privacy Law* 7(2): 76–99. <https://academic.oup.com/idpl/article-lookup/doi/10.1093/idpl/ix005>.
- Wertz, Frederick J et al. 2001. *Five Ways of Doing Qualitative Analysis: Phenomenological Psychology, Grounded Theory, Discourse Analysis, Narrative Research, and Intuitive Inquiry*.
- Wolff, Annika et al. 2014. "Developing Predictive Models for Early Detection of At-Risk Students on Distance Learning Modules." *Machine Learning and Learning Analytics Workshop at The 4th International Conference on Learning Analytics and Knowledge (LAK14)*.

**APÊNDICE A – PERGUNTAS NA ENTREVISTA COM OS
EDUCADORES PARA IDENTIFICAR AS CARACTERÍSTICAS
IMPACTANTES NA IDENTIFICAÇÃO DE EVASÃO NO EAD**

1. Qual sua formação?
2. Atualmente, você é educador(a) de qual curso?
3. Há quanto tempo você trabalha com EAD?
4. O que te levou ao EAD?
5. O que você considera como lado positivo do EAD? (Por quê?)
6. E quais você considera como os pontos negativos? (Por quê?)
7. Quais problemas os alunos costumam relatar sobre o EAD (se já tiver ouvido algum relato)?
8. Como você acha que esses problemas podem ser resolvidos?
9. Em relação as plataformas online usadas no EAD: Que recursos elas oferecem para os alunos e professores?
10. O que você mudaria nessas plataformas?
11. Muitas pesquisas apontam altos índices de abandono no EAD. Quais problemas pessoais você acha que pode levar um aluno a desistir de seu curso?
12. E quais problemas estruturais, docentes ou relacionados ao modelo de EAD podem levar um aluno a desistir de seu curso?
13. Que ações você vê sendo tomadas para diminuir esse problema do abandono?
14. Ainda falando sobre o abandono: o que você acha que poderia reduzir esse índice de abandono?
15. Algo mais que você queira acrescentar, seja com sua experiência ou algum caso, sobre esse alto índice de abandono nessa modalidade de ensino?

**APÊNDICE B – PERGUNTAS NA ENTREVISTA COM OS ALUNOS
PARA IDENTIFICAR AS CARACTERÍSTICAS IMPACTANTES NA
IDENTIFICAÇÃO DE EVASÃO NO EAD**

1. Atualmente, qual curso você estuda?
2. A quanto tempo você estuda nesse curso?
3. O que te fez optar pelo EAD?
4. Você já tinha estudado pela modalidade de EAD antes?
5. Quais você acha que sejam as vantagens do EAD? (Por quê?)
6. E quais seriam as desvantagens? (Por quê?)
7. Em relação as plataformas online que vocês utilizam: Como você vê a utilidade e importância dela?
8. Que recursos as plataformas oferecem?
9. O que você mudaria nessas plataformas?
10. Quais problemas os professores costumam relatar sobre o EAD (se já tiver ouvido algum relato)?
11. Muitas pesquisas apontam altos índices de abandono no ensino à distância. Que motivos pessoais você acha que poderia levar você ou algum colega a abandonar o curso?
12. E quais motivos relacionados a estrutura, professores, modelo das aulas, e as plataformas, você acha que poderia levar você ou algum colega a abandonar o curso?
13. Ainda falando sobre o abandono: o que você acha que poderia reduzir esse índice de abandono?
14. Que estímulos ou ações você vê sendo tomadas para diminuir esse índice de abandono dos cursos?
15. Algo mais que você queira acrescentar, seja com sua experiência ou algum caso, sobre esse alto índice de abandono nessa modalidade de ensino?

APÊNDICE C – QUESTIONÁRIO PARA COLETA DE INFORMAÇÕES SOBRE O PERFIL DOS EDUCADORES QUE REALIZARAM A AVALIAÇÃO

1. De qual(is) cursos você participa como educador? (ex: Pedagogia - UFRJ; Matemática - UFF)
Esta pergunta era obrigatória e em texto livre para escrita.
2. Quanto tempo de experiência você possui no EAD? (Em anos)
Esta pergunta era obrigatória e em texto livre para escrita.
3. Cite os motivos que você considera mais comuns para levarem alunos à abandonar seus cursos no EAD.
Esta pergunta era obrigatória e em texto livre para escrita.
4. Você usa ou já usou alguma aplicação ou aplicativo que use Inteligência Artificial?
Esta pergunta era objetiva, obrigatória e com restrição de apenas 1 escolha. As opções eram: sim; não.
5. Marque, se houver, os tipos de aplicações que você usa ou já usou.
Esta pergunta era objetiva, obrigatória e múltipla escolha.
As opções eram: Apps de reconhecimento de voz (ex. Siri da apple); Apps de apoio em Online Banking (ex. Bia do Bradesco); Robôs de assistência a compras (ex. Lu da Magazine Luiza); Apps que recomendam músicas, filmes, etc (ex. Spotify, Netflix); Algum canal de atendimento eletrônico feito por robôs/chatbots (ex. Sky, Oi); Apps para roteamento e localização (ex. Waze, Google Maps); Serviços de email com detecção automática de spam (ex. GMail); Serviços de busca (ex. Google, Mercado Livre, Airbnb); outros (escreva quais).
6. Qual o seu grau de satisfação sobre as respostas dadas pelas Apps que você usa ou já usou?
Esta pergunta era objetiva, obrigatória e com restrição de apenas 1 escolha. As opções eram: nenhuma satisfação; pouca satisfação; indiferente; satisfeito; muito satisfeito.
7. Se desejar, comente sua escolha acima.
Esta "pergunta" era opcional, caso o educador quisesse descrever melhor sua escolha na questão 6.
8. Qual o seu grau de confiança sobre as respostas dadas pelas Apps que você usou ou já usou?
Esta pergunta era objetiva, obrigatória e com restrição de apenas 1 escolha. As opções eram: não confio; confio pouco; indiferente; confio razoavelmente; confio muito.
9. Se desejar, comente sua escolha acima.
Esta "pergunta" era opcional, caso o educador quisesse descrever melhor sua escolha na questão 8.
10. Você notou algum tipo de viés (cultural ou social, por exemplo) nas respostas durante o uso destes apps com IA?
Esta pergunta era objetiva, obrigatória e com restrição de apenas 1 escolha. As opções eram: sim; não.

11. Se sim, poderia citar algum desses casos?

Esta "pergunta" era opcional, caso o educador quisesse descrever melhor sua escolha na questão 10.

APÊNDICE D – QUESTIONÁRIO PARA COLETAR INFORMAÇÕES SOBRE A OPINIÃO DOS EDUCADORES APÓS O USO DA FERRAMENTA

1. Você consultou a situação de alunos classificados pela IA Árvore de Decisão como "Sim" (evadir) e "Não" (não evadir). O quanto você concorda com as previsões da Árvore de Decisão?

Esta pergunta era objetiva, obrigatória e com restrição de apenas 1 escolha. As opções eram: não concordo; concordo pouco; concordo parcialmente; concordo na maioria dos casos; concordo totalmente

2. Explique sua opção acima.

Esta "pergunta" era opcional, caso o educador quisesse descrever melhor sua escolha na questão 1.

3. Após os testes, quais atributos você acredita que a Árvore de Decisão considera como mais importante para realizar suas previsões? Tome como exemplo algum aluno que você selecionou e usou para fazer simulações. Se for preciso volte ao site <https://dropict.com.br/>
Esta pergunta era objetiva, obrigatória e múltipla escolha. As opções eram todos os atributos dispostos nas edições de cenário.

4. Explique sua opção acima.

Esta "pergunta" era opcional, caso o educador quisesse descrever melhor sua escolha na questão 3.

5. Algumas pesquisas indicam que aplicações com IAs podem conter decisões equivocadas ou vieses culturais, como preconceitos, por exemplo. Você encontrou algum problema ou tipo de preconceito nas previsões da Árvore de Decisão?

Esta pergunta era objetiva, obrigatória e com restrição de apenas 1 escolha. As opções eram: sim; não.

6. Caso tenha encontrado algum problema ou forma de preconceito, descreva-o.

Esta "pergunta" era opcional, caso o educador quisesse descrever melhor sua escolha na questão 5.

7. As simulações e os cenários te ajudaram a entender e questionar os resultados das IAs?

Esta pergunta era objetiva, obrigatória e com restrição de apenas 1 escolha. As opções eram: não me ajudaram em nada; não me ajudaram muito; indiferente; me ajudaram razoavelmente bem; me ajudaram muito.

8. Se desejar, explique a escolha acima.

Esta "pergunta" era opcional, caso o educador quisesse descrever melhor sua escolha na questão 7.

APÊNDICE E – TERMO DE CONSENTIMENTO PARA PARTICIPAÇÃO DA AVALIAÇÃO DE SIMULAÇÕES ATRAVÉS DA FERRAMENTA DROPICT

TERMO DE CONSENTIMENTO LIVRE E ESCLARECIDO (TCLE)

UNIVERSIDADE FEDERAL FLUMINENSE

INSTITUTO DE COMPUTAÇÃO

DROPICT: SIMULAÇÃO DE CENÁRIOS PARA INVESTIGAÇÃO DE MODELOS
PREDITIVOS DE ALUNOS EM RISCO DE EVASÃO NA EDUCAÇÃO À DISTÂNCIA

Pesquisador Responsável: Rômulo Ponciano da Silva Freitas

Telefone para contato: (21) 9670-33319 Email: romuloponciano@id.uff.br

Nome do voluntário:

O(A) Sr.(a) está sendo convidado(a) a participar do projeto de pesquisa “DROPICT: SIMULAÇÃO DE CENÁRIOS PARA INVESTIGAÇÃO DE MODELOS PREDITIVOS DE ALUNOS EM RISCO DE EVASÃO NA EDUCAÇÃO À DISTÂNCIA”, desenvolvida no Instituto de Computação da Universidade Federal Fluminense (UFF), por meio do Programa de Pós-Graduação em Computação (PPGC), sob responsabilidade da professora Dra. Luciana Salgado orientando o mestrando Rômulo Ponciano.

Esta pesquisa tem como objetivo verificar se o uso de simulações e cenários pode ser usado como meio para que educadores do EAD consigam questionar, validar e encontrar falhas em modelos de Inteligência Artificial, construídos para a predição de alunos risco de evasão. Para isso, desenvolvemos um protótipo que permite a interação entre usuário e Inteligência Artificial, através de um simulador de cenários. Então, precisamos de educadores do Ensino à Distância para usar este protótipo e responder um questionário ao final.

Assim sendo, o(a) sr.(a) participará do estudo por meio desses testes e do questionário final, onde responderá perguntas sobre os modelos que aparecem no teste. Todas as perguntas e todo o assunto tratado no questionário envolve os modelos presentes no protótipo e sua experiência como educador do EAD. Os dados utilizados para a construção dos modelos estão anonimizados e seus dados não serão coletados.

Durante todo o processo, se o(a) sr.(a) se sentir desconfortável por qualquer motivo que seja, poderá abandonar os testes no mesmo momento sem nenhuma necessidade de explicação a este pesquisador ou a qualquer outra parte relacionada a esta pesquisa. Caso ocorra a interrupção do processo, sem seu desejo, recomendamos que reinicie o processo.

É importante conhecer que esta pesquisa poderá educadores do Ensino à Distância possam utilizar modelos preditivos entendendo e questionando seus resultados.

Por fim, nós garantimos a confidencialidade e privacidade do(a) sr.(a). Não iremos incluir, sob nenhuma hipótese ou circunstância, o nome ou outras informações pessoais, de qualquer participante ao qual tivemos contato para a realização desta pesquisa, mesmo que o participante não tenha recusado ou desistido da entrevista.

Como esta pesquisa é de participação voluntária, sem nenhum custo para o participante, seu consentimento poderá ser retirado a qualquer tempo, sem nenhuma espécie de prejuízo ou qualquer outra penalização. Além disso, esta pesquisa também não irá fornecer nenhum pagamento, em nenhuma forma, para aqueles que participarem da entrevista. Portanto, nenhum gasto do voluntário, como transporte ou alimentação, será provido ou ressarcido.

Para sanar qualquer dúvida referente aos procedimentos, riscos, benefícios e outros assuntos relacionados com a pesquisa, basta entrar em contato com o pesquisador responsável pela forma desejada presente no topo deste termo.

Os Comitês de Ética em Pesquisa (CEPs) são compostos por pessoas que trabalham para que todos os projetos de pesquisa envolvendo seres humanos sejam aprovados de acordo com as normas éticas elaboradas pelo Ministério da Saúde. A avaliação dos CEPs leva em consideração os benefícios e riscos, procurando minimizá-los e busca garantir que os participantes tenham acesso a todos os direitos assegurados pelas agências regulatórias. Assim, os CEPs procuram defender a dignidade e os interesses dos participantes, incentivando sua autonomia e participação voluntária. Procure saber se este projeto foi aprovado pelo CEP desta instituição. Em caso de dúvidas, ou querendo outras informações, entre em contato com o Comitê de Ética da Faculdade de Medicina da Universidade Federal Fluminense (CEP FM/UFF), por e.mail ou telefone, de segunda à sexta, das 08:00 às 17:00 horas: E.mail: etica@vm.uff.br Tel/fax: (21) 26299189

Eu, _____, declaro ter sido informado e concordo em ser participante, do projeto de pesquisa acima descrito.

_____, ____ de _____ de _____

_____ (assinatura do participante)

_____ (assinatura do responsável por obter o consentimento)